

分类号_____ 密级_____
UDC _____ 编号_____



云南师范大学
YUNNAN NORMAL UNIVERSITY

硕士研究生学位论文

论文题目：基于深度学习的印刷电路板组件检测研究

英文题目：Research on Printed
Circuit Board Component Detection Based
on Deep Learning

学 院_____信息学院_____

专业名称_____计算机类_____

研究方向_____计算机应用技术_____

研究生姓名 _____戴亨_____ 学号 _____2223100014_____

导 师 姓 名 _____张云港_____ 职 称 _____副教授_____

2025 年 5 月 25 日

摘要

随着电子产品向小型化和高集成度的发展，印刷电路板（Printed Circuit Board, PCB）在自动化生产线和智能制造环境中，对快速且准确的 PCB 组件检测算法的需求愈加迫切，尤其是在确保电子产品质量和可靠性方面，还可以减少残次品回收从而降低成本。尽管目前 PCB 组件检测技术取得了一定的进展，各种先进的检测算法层出不穷，但仍面临着目标较小、数据样本少而导致的精度低、漏检率高的问题。针对上述挑战，本文基于深度学习的方法对 PCB 表面组件检测技术进行研究，重在提升检测精度同时兼顾检测速度，本文主要研究内容如下：

1. 目前针对 PCB 组件检测任务的数据集较少，本文整合了 FICS 与 pcb_wacv_2019 公共数据集，通过几何变换（旋转、翻转）与色彩空间增强（随机亮度/对比度）构建专用数据集 SPCB-Datasets，涵盖 14602 张图像。

2. 为解决 PCB 组件检测目前面临的精度低、实时性差的问题，提出了基于 YOLOv8n 的组件检测模型 DFBA-YOLOv8，本文通过对模型的主干（Backbone）、特征融合（Neck）和检测头（Head）三个部分分别进行了相应的改进。在主干网络部分，本文引入高效的卷积模块提取高层特征；加入关注感受野的卷积替换原网络中下采样操作的 C2f 结构，提升模型定位的精度，改善网络特征提取的整体性能和效率；在特征融合部分，论文提出了一种基于 BiFPN 改进的 BPFPN 的多尺度特征融合结构；在检测头部分，针对 PCB 微小组件检测任务，舍弃了较大目标检测头，增加了较小目标检测头，提出了基于注意力机制的检测头 AMD_Detect Head 替换原检测头。实验表明该模型在数据集上达到了 88.6% 的 mAP@0.5 检测精度，同时获得了 103FPS 的检测速度。

3. 为解决 PCB 组件较小、较为相似的特性而导致容易出现漏检错检的现象，并且为了进一步提升检测精度，本文基于 RT-DETR 模型设计了 EfficientPCB-DETR 模型，选取了高效的 Efficient FormerV2 主干网络替换原有主干、使用 HiLo 注意力优化 AIFI 中的多头自注意力，同时，本文方法使用了轻量化设计的上采样模块。实验表明，所提模型取得了 92.5% 的 mAP@0.5 检测精度，同时，该模型仍有 64FPS 的检测速度，在保证检测速度的同时，获得了较好的检测精度。

4. 为了验证本文所提出模型在 PCB 硬件保障中的通用性和有效性，本文所提方法在公开的 PCB 缺陷数据集上也获得了较好效果，验证了所提模型在 PCB 缺陷检测的应用可行性。

关键字：PCB 组件检测；深度学习；小目标检测；YOLOv8；RT-DETR

Abstract

With the increasing miniaturization and integration of electronic devices, there is a growing demand for rapid and accurate printed circuit board (PCB) component detection algorithms in automated production lines and intelligent manufacturing environments. Effective detection technology is crucial for ensuring product quality and reliability while reducing costs through minimizing defective product recalls. Although current PCB component detection technologies have achieved progress with various advanced algorithms, significant challenges remain, including low accuracy and high false-negative rates caused by small target sizes and limited training data.

To address these challenges, this study investigates deep learning-based methods for PCB surface component detection, focusing on improving detection accuracy while maintaining processing speed. The main contributions are summarized as follows:

1. To mitigate the scarcity of specialized PCB component datasets, we integrate two public datasets (FICS and PCB_WACV_2019) and implement comprehensive data augmentation strategies. These include geometric transformations (rotation, flipping, transposition) and color space adjustments (random brightness/contrast). Following the FICS methodology, all images are uniformly resized to 640×640 pixels to optimize feature extraction by neural networks.

2. To enhance detection accuracy and real-time performance, we propose DFBA-YOLOv8, an optimized architecture based on YOLOv8n. Key improvements include: A redesigned backbone incorporating efficient convolution modules for enhanced high-level feature extraction; Replacement of the original C2f downsampling structure with receptive field-aware convolutions to improve localization precision; A BPFPN multi-scale feature fusion module derived from BiFPN, prioritizing small-object detection heads while eliminating redundant large-target detection heads; An attention-enhanced AMD_Detect Head replacing the original detection module. Experimental results demonstrate 88.6% mAP@0.5 accuracy with 103 FPS processing speed, achieving superior performance on PCB component detection tasks.

3. Addressing challenges in detecting miniature and morphologically similar components, we develop EfficientPCB-DETR based on RT-DETR. Major innovations include: An EfficientFormerV2 backbone for lightweight feature extraction; HiLo attention mechanisms optimizing the multi-head self-attention in AIFI modules; Streamlined upsampling blocks for computational efficiency. The model achieves state-of-the-art performance with 92.5% mAP@0.5 and maintains practical applicability at 64 FPS.

4. To verify model generalizability, we conduct comparative experiments on public PCB defect datasets using identical preprocessing protocols. Results confirm the consistent superiority of our proposed architectures in industrial hardware assurance applications.

Key words : PCB component detection; Deep learning; Small object detection; YOLOv8; RT-DETR

目录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.2.1 传统方法的印刷电路板检测现状	2
1.2.2 基于机器学习的 PCB 检测方法	4
1.2.3 基于深度学习的 PCB 检测方法	4
1.3 本文研究的主要内容	7
1.4 本文结构安排	7
第 2 章 PCB 组件检测研究相关技术及理论	9
2.1 PCB 表面组件研究	9
2.1.1 PCB 制造工艺	9
2.1.2 PCB 表面组件分析	9
2.1.3 PCB 表面组件检测存在的问题	10
2.2 卷积神经网络理论研究	11
2.2.1 卷积神经网络	11
2.2.2 输入层	12
2.2.3 卷积层	12
2.2.4 池化层	13
2.2.5 全连接层	15
2.2.6 输出层	16
2.3 目标检测算法概述	18
2.3.1 基于候选窗口的两阶段目标检测算法	18
2.3.2 基于回归的单阶段目标检测算法	19
2.4 PCB 组件检测算法评价指标	22

2.5 本章小结	24
第3章 基于 YOLOv8 的 PCB 组件检测算法研究	25
3.1 引言	25
3.2 YOLOv8 目标检测算法研究	25
3.2.1 网络结构	26
3.2.2 损失函数	30
3.3 基于 YOLOv8 的 PCB 微小组件检测算法	32
3.3.1 DFBA-YOLOv8 模型	32
3.3.2 引入可变形卷积 DCNv4 结构	33
3.3.3 RFACnv 关注感受野的卷积模块	36
3.3.4 基于 BiFPN 的多尺度特征融合	39
3.3.5 基于注意力机制的动态检测头	40
3.4 实验结果及分析	43
3.4.1 SPCB-Datasets 数据集	43
3.4.2 实验环境及实验参数设置	46
3.4.3 消融实验	47
3.4.4 对比实验及效果展示图	48
3.5 本章小结	51
第4章 基于轻量化 RT-DETR 的 PCB 组件检测算法研究	52
4.1 Transformer 模型概述	52
4.2 DETR 模型理论基础	54
4.3 RT-DETR 目标检测算法	55
4.4 针对 PCB 组件检测任务的轻量化改进 RT-DETR 模型算法	58
4.4.1 EfficientPCB-DETR 模型	59
4.4.2 主干网络改进	60
4.4.3 基于注意力机制的改进 AIFI	61
4.4.4 轻量化上采样改进	63
4.5 实验结果及分析	64
4.5.1 数据集、实验环境及训练设置	64
4.5.2 实验结果	65
4.5.3 主干网络消融实验	65

4.5.4 消融实验	66
4.5.5 对比实验及效果图展示	67
4.6 本章小结	69
第 5 章 模型在 PCB 硬件保障中的通用性研究	71
5.1 引言	71
5.2 PCB 缺陷检测数据集	71
5.3 基于深度学习的 PCB 缺陷检测研究现状	73
5.4 对比实验研究	73
5.5 本章小结	79
第 6 章 总结与展望	80
6.1 工作总结	80
6.2 工作展望	81
参考文献	81
攻读硕士学位期间发表的学术论文	87
致谢	87

第 1 章 绪论

1.1 研究背景和意义

印刷电路板(Printed Circuit Board, PCB)作为现代电子系统的核心组成部分,在从消费电子到国防和医疗设备的广泛应用中发挥着关键作用。从智能手机、个人计算机到军事武器系统和生命支持设备,PCB 几乎无处不在,承担着连接和控制电子元件的核心功能。然而,随着工业 4.0 时代的到来,物联网(IoT)和人工智能(AI)技术正在重新定义 PCB 生产流程,同时也带来了前所未有的挑战和机遇^[1]。PCB 是现代电子信息产业的支柱,承载着集成电路、电阻器、电容器等电子元器件。电子技术的快速发展导致了 PCB 的小型化、集成化和多样化^[2]。表面贴装技术实现了元器件的高密度、高速度的自动组装。在制造和装配过程中,PCB 元件的快速、精确识别和定位变得越来越重要^[3]。随着技术的进步,制造业正在向数字化转型迈进,致力于实现自主运营和生产高质量电子产品。机器视觉技术已成为现代电子制造中的关键工具,在 PCB 检测领域尤为重要。自动光学检测(Automatic Optical Inspection, AOI)系统已经被广泛应用于 PCB 生产中,用于快速识别并消除缺陷^{[4][5]}。然而,随着全球化供应链的发展,PCB 制造呈现外包化趋势,这一趋势虽然提高了生产效率,却也引发了严峻的安全挑战^[6]。例如供应链的复杂性及透明度不足导致 PCB 易受恶意篡改,尤其是硬件木马的潜在威胁。这些攻击提供了对敏感网络的后门访问,可能导致国家关键基础设施、军事装备和敏感民用系统的安全隐患,甚至影响社会经济秩序,因此,PCB 组件识别是早期发现 PCB 缺陷的必要前提,对 PCB 行业的质量控制成本有着深远的影响,故在部署之前检查 PCB 硬件安全是至关重要的。电阻器、电容器和晶体管等常见电子元件是假冒问题的重灾区,上述的几种元器件都是每一个 PCB 上必备的、不可或缺的组件,其功能异常可能导致整个 PCB 失效^[7]。精确的组件检测在自动化 PCB 生产监控中至关重要,尤其是在应对诸如表面贴装技术(SMT)贴装过程中组件移位或缺失等关键制造缺陷时^{[8][9]}。为有效解决这些问题,提升自动化 PCB 检测工具的性能成为必要条件。准确定位组件位置可以提升缺陷检测效率,支持组件特性识别,并为 PCB 回收与再利用提供技术支撑。

一个 PCB 通常包含数百个组件,组件类型的识别需要对电子组件有深入地了解,专家通常需要一到两天的时间来标记单个 PCB 图像。因此,如果我们能将这个繁琐的过程自动化,那将是非常有帮助的。对于有限的数据量的挑战而言,一张 PCB 板需要由有一定电路知识的学者对图像进行标记工作,每张 PCB 电路

板上的组件个数相对于其他任务而言较多，标记工作需要一定的时间和成本。而要运用深度学习的方法来完成该任务，需要大量的有标记的组件的 PCB 图片，于是我们的工作还包括收集，制作数据集，来使网络模型有更强的泛化性^[10]。

目前小型化和高集成度的趋势使得传统的检测方法在准确性、速度和适应性方面面临重大挑战。其复杂性主要源于组件在尺寸、方向和布局上的多样性，对于一张 PCB 板，它上面的组件例如电阻、电容器等，在人眼下就极难分辨，组件小而密集，类间相似度高。现代 PCB 设计通常包含复杂的组件布局 and 多层电路，这种复杂性使得检测算法必须能够处理多种不同的组件和电路结构，增加了检测的难度。在表面贴装技术过程中，组件可能会因贴装不当而移位或缺失。这种情况需要检测系统具备高灵敏度，以便及时发现并纠正这些缺陷。在自动化生产线上，检测系统需要实时工作，以确保生产效率和产品质量。这对检测系统的响应速度和处理能力提出了更高的要求。所以从研究的实际价值出发，本文针对 PCB 组件检测任务提出的高精度、高实时性方法是十分有应用价值和意义的。

此外，PCB 组件检测的研究还是逆向工程的前置工作，不仅具有重要的工业应用价值，还在学术界引发了广泛关注^[11]。通过深入研究检测算法，可以推动机器学习、图像处理等领域的理论发展，促进跨学科的技术融合。更重要的是，随着电子产品日益普及，确保产品质量和安全性已成为社会各界的共同关注。因此，PCB 组件检测的研究不仅是技术创新的需求，也是社会责任的体现，其研究成果将为电子制造行业的可持续发展提供强有力的支持。

1.2 国内外研究现状

1.2.1 传统方法的印刷电路板检测现状

在传统的工业制造中，人们对于印刷电路板生产后的检测主要包括人工检查：通过人眼观察 PCB，检查焊点、元器件安装、线路完善性等。这是最基本的检测方法，适合初步识别明显的缺陷。人工检查在小型企业及低产量、高复杂度的 PCB 原型制作中仍有应用。操作员通常会根据经验和技能来判断组件的质量。其缺点也非常明显，人工检查的速度远不及自动化检测，尤其是在大规模生产中，可能成为生产瓶颈，同时误差也相对较大，由于人为因素如疲劳、注意力不集中等，可能导致漏检或误判，影响产品质量。传统方法还包括电气测试：电气测试主要用于验证 PCB 的功能性，确保电路在实际使用中能够正常工作，常见的电气测试方法包括飞针测试和功能测试，该方法能够直接验证 PCB 的电气性能，确保电路功能的完整性，但是该方法通常需要额外的时间和设备，可能延长生产

周期，而且电气测试无法有效检测到物理缺陷，如焊接不良或组件位置偏差等。

在机器学习技术普及之前，基于传统图像处理的 PCB 元器件检测尝试较为有限。在 PCB 元器件的工业质检场景中，常规影像处理技术常基于信号处理理论框架，涵盖频域分析（如傅里叶频谱解析）、特征空间降维（主成分分解）、多尺度特征提取（离散小波分解）以及模板几何配准等核心算法体系。其中傅里叶变换适用于周期性焊点缺陷检测，主成分分析实现高维图像数据的低维表征，小波变换则通过时频联合分析定位微型元件缺陷，而基于特征描述子的模式匹配算法完成元件位置姿态的精确比对。这四种技术并非孤立存在，而是相互交融，共同形成了非分类器的 PCB 缺陷检测体系。其中，最常见的应用是将其他方法与图像模式匹配相结合，以实现 PCB 质量的有效评估。

在传统的 PCB 板研究中，Hassanin 等^[12]提出了一种自动故障检测方法，利用数字图像处理技术，如配准、滤波和前景分割，并结合加速稳健特征技术，能够实现对 PCB 图像中故障的精准检测。Polat 等人^[13]则提出了一种创新的视觉方法，结合三维点云数据和高光谱成像（HSI）技术，全面提取 PCB 上各类组件的几何和光谱特征，为电子废料处理和回收提供了新的思路。Kim 等人^[14]提出了一种自动图像分割方法，通过转换 HSI 颜色模型、应用聚类方法以及改进的 k 均值算法，准确地从 PCB 图像中提取组件检测区域，并进行精确分割与定位。

尽管传统方法在 PCB 板组件分割和故障检测领域取得了一些进展，然而其固有的缺陷仍暴露其应用瓶颈，这些方法在复杂工况下普遍面临特征表征能力不足与泛化性能受限等问题。在 PCB 硬件保证领域，现有的大部分工作都集中在缺陷检测上，这些工作同样能给我们带来启发。例如 Xie F^[15]提出了一种使用遗传算法的放置缺陷检测方法。在这类方法中，缺陷的定义参照了黄金样本，即无缺陷样本。造假者和对手故意模糊设计，使检测变得困难但黄金样本可能并不总是可用。Yuk E H 等人^[16]和 Lu Z 等人^[17]提出了基于特征的方法检测（例如，颜色、照明、背景和倾斜物体），但它们解决的是特定问题，而不是整体的 PCB 保证。因此替代的方法如自动提取材料清单已被提出作为一种额外的硬件保证方法，是对缺陷检测的补充。

虽然传统的 PCB 检测方法多样，但是始终存在一定的局限：首先如人工检查和某些类型的自动检测，速度相对较慢，无法满足大规模生产的需求，可能导致生产效率的降低；其次，检测精度普遍较低，无法满足对高精度检测的需求；此外，虽然某些检测设备具备较高的精度，但其检测速度较慢，无法实现实时监测，因此这类方法逐渐被人们所忽视。

1.2.2 基于机器学习的 PCB 检测方法

PCB 组件在类型、外观和尺寸上都有很大的不同。这使得传统的基于人类视觉的检测方法无效且容易出错。因此, 这些方法无法满足自动化生产^[18]的实际要求。为了减轻对人工检测的依赖, 与机器视觉相结合的自动光学检测技术得到了广泛地实施, 尤其是在现代工厂^[19]中。

研究人员提出了多种基于机器视觉的 PCB 元件检测方法。他们对遗传算法等传统的机器学习算法进行了修改然后应用采用混合遗传算法、随机森林像素分类器、模板匹配、粒子群优化算法对 PCB 组件进行分类识别。然而, 这些方法都有其固有的缺点: PCB 元件检测的机器学习算法与图像处理紧密结合通常需要合格的模板。

Crispin 等人^[20]应用遗传算法结合归一化相互关联 (NCC) 模板匹配来定位和识别 PCB 中的电阻。每张小尺寸图像的平均推理时间达到了 39.5s。但是, 这种方法的计算成本较大, 导致运行速度较慢。此外, 遗传算法的合格模板的构建和最优参数的选择都是复杂和经验的, 导致检测效率较低。Mashohor 等人^[21]提出了一种混合遗传算法来检测缺失元件和分段焊点。在图像处理技术的帮助下, 该方法识别了缺失的组件或焊点, 但未能对其进行分类。Li 等人^[22]利用随机森林像素分类器对 PCB 的深度图像进行成分分割。对真实 PCB 图像的组分识别率为 83.64%。Yin^[23]设计了一种多级模板匹配算法来检测 PCB 元件。首先实现快速粗匹配, 定位相似区域然后进行精确匹配, 估计相似区域是否为目标元件。该方法检测电阻、电感和电容的精度分别为 95.3%、94.1%和 96.5%。Wang^[24]将多模板匹配和基于物种的粒子群优化算法结合起来对 PCB 组件进行检测。群优化的加入降低了计算成本。6 个电阻器的平均检测率为 100%对于 762×612 像素图像, 最佳平均运行时间约为 25.96s。Dong 等人^[25]提出了一种改进的粒子群优化算法, 借助模板匹配来检测 PCB 组件。该粒子群优化器使用混沌和物种的概念来确定邻域最优值。

传统机器学习方法多采用两阶段或多阶段流程: 首先通过图像处理技术定位目标, 再应用分类算法进行识别。这些图像处理操作和机器学习算法通常计算复杂的矩阵, 具有很高的运行时间复杂度, 导致巨大的计算成本。这些机器学习算法的参数偏好和优化也可能是一项繁重的任务, 因此它们难以高速处理高分辨率 PCB 图像。

上述文献的检测结果与人工设计的特征密切相关, 这些特征通常通过传统图像处理方法提取。在图像预处理阶段, 通常需要将模板与待检测图像进行匹配。然而, 获取理想的模板既繁琐又成本高昂。此外, 模板与测试图像之间必须保持

像素级的对齐,以避免引入额外噪声。为了确保良好的检测性能,复杂且稳定的照明条件是必不可少的。传统的基于机器学习的 PCB 检测方法虽然在检测性能上表现良好,但仍然存在一定的局限性。为了实现高精度和准确的目标定位,这些方法通常需要执行多种图像处理操作。例如,模板匹配或图像减法等技术依赖于完美的模板,而模板对环境变化极为敏感。因此,这些方法的泛化能力较差,鲁棒性也相对较弱。此外,它们通常是多阶段的处理流程,导致在实际应用中难以满足当前对实时性和自动化检测的需求。

1.2.3 基于深度学习的 PCB 检测方法

在电子制造技术持续革新的背景下,PCB 作为电子系统的核心载体,其工艺质量对终端产品的功能稳定性与服役寿命具有决定性影响。这一客观现实使得构建精密化的 PCB 缺陷检测体系成为现代电子工业质量管控流程中不可或缺的关键环节。传统的检测方法(如人工检测和光学检测)往往效率低、准确性不足,难以满足现代制造业的需求。近年来,深度学习技术的引入为 PCB 检测提供了新的解决方案,能够显著提高检测的自动化程度和准确性。

Mamidi 等人^[26]提出了一种基于 YOLOv4-tiny^[27]网络的 PCB 检测系统,用于识别 PCB 表面缺陷。Lan 等人^[28]设计了一种改进的 YOLOv3 网络来检测 PCB 表面缺陷。将批归一化层与卷积层结合,提高前向推理速度。利用 GIoU 损失函数提高模型对小目标的检测效果。此外,应用 kmeans++ 聚类来获得更合适的锚点。该方法的 mAP 率为 92.13%,检测速度为 63FPS,优于原有的 YOLOv3 模型。Li CJ^[29]提出了一种基于扩展 FPN 的 PCB 板缺陷检测算法。骨干网是建立在 ResNet-101 之上的。为了准确地对 PCB 缺陷进行分类,引入了焦点损失函数,该方法实现了在公共数据集中 6 类 PCB 表面缺陷的检出率 mAP 为 96.2%。

Evangelidis 等人^[30]通过引入数据驱动的软传感器模型,提出了一种用低成本传感器取代昂贵实验室传感器的方法。在该方法的帮助下,设计了一个胶水沉积的 PCB 检测系统,该系统依赖于工业相机和 Jetson AGXXavier 单元,提出了一种基于 Mask R-CNN^[31]和 Faster R-CNN^[32]的实例分割网络,用于预测每个胶沉积的坐标并对其类型进行分类。然后,提出了一种改进的残差架构(R2esNet),用于胶沉积的体积估计。该方法对 PCB 制造中的胶缺陷进行了较为满意的检测,有效地方便了质量检测过程,优化了生产工艺。

Li 等人^[33]提出了一种改进的 YOLOv3 来检测 PCB 元件其中增加了一个额外的输出层。PCB 元器件的检测 mAP 达 93.07%。然而,引入额外的预测层带来了额外的计算延迟了推理。与上面的重量级模型相比,Shen 等人^[34]提出了一种轻量级深度学习模型,该模型集成了 FasterRCNN 和 PeleeNet,可以对各种 PCB 组

件进行快速精确的检测。该方法检测精度达到 85.8%，检测速度达到 27FPS。Zhang 等人^[35]只是使用 YOLOv3 来识别 PCB 元件没有任何修改。对 11 种 PCB 元件的总体检测率约为 92% 每个输入图像的运行时间为 0.55s。

Chen 等人^[36]基于深度卷积和可分离卷积设计了一种简单的 CNN 模型来对正常分量和缺陷分量进行分类。合格品和次品的检测精度分别达到 96.96% 和 95.70%。每个部件的平均推断时间达到 27ms，几乎是实时的。然而，它只检测到 42×42 像素的小区域，而不是整个 PCB 图像。

Liu 等人^[37]提出高斯 IoU(GsIoU) 损失函数用于边界盒回归，以取代 YOLOv4 中原有的损失函数。GsIoU 的引入使 mAP 比基线增加了 3.3%。然而，该数据集仅包含 6 种类型的 PCB 组件，这些组件都是大尺寸或中等尺寸，并且在板中稀疏地封装双列。因此，这种方法可能难以检测微小和密集的 PCB 组件。

随着深度学习在硬件设备上的进一步发展，Mantravadi 等人^[38]提出了一种轻量化的神经网络 DInPNet，用于 PCB 组件分类。DInPNet 采用逆特征卷积替代传统的卷积操作，并引入扩张逆特征卷积金字塔块，使得网络能够学习到更大范围的有效接受域，从而在大型 PCB 图像中进行高效的特征提取。通过这种轻量化设计，DInPNet 在不牺牲精度的情况下，显著减少了计算资源的消耗，实验结果显示该网络超越了现有的深度学习方法，尤其在处理复杂布局的 PCB 时，表现出优异的性能。

Benjumea A 等人^[39]基于 YOLOv5 提出了小目标检测器 YOLO-Z，在这项研究中，作者探索了涉及高分辨率特征映射的重定向连接的效果，以便将它们直接反馈到 Neck 和 Head，通过扩大 Neck 以适应额外的特征图来实现，也可以通过替换最低分辨率的特征图以适应新的特征图来实现小目标检测，相比原 YOLOv5 得到 6.9% mAP 的改善。

QIN 等人^[40]通过在 YOLOv8 上引入一些修改，提出了一种新的基于卷积神经网络模型，用于密集 PCB 组件检测。首先，创造性的 C2Focal 模块被设计为骨干的核心元素，同时结合了细粒度的局部和粗粒度的全局特征。然后，插入轻量级 Ghost 卷积，有效降低计算成本，同时保持检测性能。最后提出了一种新的边界盒回归损失 Sig-IoU 损失。在论文数据集上达到了 87.7% 的 mAP 和 110 的 FPS。

一系列相关的研究突破与技术革新，为 PCB 领域的自动化分析及制造流程奠定了坚实的技术基础。在深度学习技术的推动下，PCB 检测的精度、速度和适应性都得到了大幅提升，使得智能化 PCB 生产成为可能。随着技术的不断发展，预计在未来的 PCB 生产流程中，智能化和高效化将成为主要发展趋势。特别是在自动化检测、缺陷识别以及元件分类等领域，深度学习的应用预计将发挥

关键作用。这种深度学习技术的应用不仅有望显著提升 PCB 生产过程的效率与产品质量,而且预期将为相关产业带来生产力的跃升和制造成本的降低,从而进一步推动工业制造向智能化、自动化方向转型升级。

1.3 本文研究的主要内容

本文针对 PCB 组件检测任务面临的目标较小、数据样本少和目前该领域模型检测精度低、漏检率高的问题,做出了以下研究:

(1) 目前针对 PCB 组件检测任务的数据集较少,本文收集了 FICS 数据集和 pcb_wacv_2019 两种公共数据集,并进行了一系列数据增强处理包括旋转、翻转、转置和随机亮度对比度在内的色彩空间转换,并且借鉴 FICS 的思想将图片统一裁剪成 640×640 大小,可以让网络更好地提取学习组件特征。

(2) 为解决 PCB 组件检测目前面临的精度低、实时性差的问题,提出了基于 YOLOv8n 的组件检测模型 DFBA-YOLOv8,本文通过对模型的 Backbone、Neck 和 Head 三个部分分别进行相应的改进,引入高效的卷积模块提取高层特征;加入关注感受野的卷积替换原网络中下采样操作的 C2f 结构,提升模型定位的精度,改善网络的整体性能和效率;提出了一种基于 BiFPN 改进的 BFPN 的多尺度特征融合结构,针对 PCB 微小组件检测任务舍弃了较大目标检测头,增加了较小目标检测头;提出基于注意力机制的检测头 AMD_Detect Head 替换原检测头。实验表明该模型在我们的数据集上达到了 88.6%的 mAP@0.5 检测精度,同时我们的模型获得了 103FPS 的检测速度,取得良好的效果。

(3) 为解决 PCB 组件较小、较为相似的特性而导致容易出现漏检错检的现象,并且为了达到工业上对于检测精度的要求,本文基于 RT-DETR 模型设计了 EfficientPCB-DETR 模型,选取了高效的 EfficientFormerV2 主干网络替换原有主干、使用 HiLo 注意力优化 AIFI 中的多头自注意力以及使用轻量化设计的上采样模块。实验表明该模型在我们的数据集上取得了 92.5%的 mAP@0.5 最高检测精度,同时该模型仍有 64FPS 的检测速度,取得良好的效果。

(4) 为了验证本文所提出模型在 PCB 硬件保障领域的通用性和有效性,使用公开的 PCB 缺陷数据集进行实验,采用相同数据增强策略,通过对比分析证明了我们的模型在硬件保障领域的有效性与泛化能力。

1.4 本文结构安排

本文总共将全文分为六个章节来进行阐述所提出的 PCB 组件检测算法,每

个章节的内容分别如下：

第一章是本文的绪论部分。本章节首先阐述了本研究的背景和意义，明确了该任务在工业应用中是不可或缺的，其次介绍了国内外的 PCB 组件检测领域的研究现状，分为传统、基于机器学习和基于深度学习三个方面介绍，最后简单地介绍了本文研究的主要内容。

第二章主要介绍的是本文所涉及的相关基础理论知识。本章节首先介绍了 PCB 的制造工艺并分析了常见的组件类型和组件检测中的难点。其次详细介绍了卷积神经网络的相关基础理论，包括输入层、卷积层、池化层、全连接层以及激活函数层。后介绍了目标检测算法，分为两阶段和单阶段详细介绍了各种目标检测方法。最后介绍了 PCB 组件检测的相关评价指标。

第三章首先详细介绍了 YOLOv8n 目标检测算法，包括网络结构和损失函数。随后介绍了基于 YOLOv8n 提出的针对 PCB 组件检测任务的 DFBA-YOLOv8 模型，包括可变形卷积、关注感受野的卷积、多尺度的小目标特征融合模块和注意力机制检测头。最后通过对比实验和消融实验证明模型的有效性。

第四章首先详细介绍了 Transformer 模型的理论基础，后介绍了 DETR 和 RT-DETR 目标检测模型的理论。随后介绍了基于 RT-DETR 提出的更高效的 EfficientPCB-DETR 模型，包括主干网络的替换、基于注意力改进的 AIFI 模块和轻量化的设计。最后通过对比实验和消融实验证明模型的有效性。

第五章先介绍了前人在 PCB 缺陷检测中的研究，其次介绍了公开的 PCB 缺陷数据集和数据增强处理，后进行了大量的对比实验，验证本文提出模型在 PCB 硬件保障领域的通用性。

第六章对全文研究工作进行了总结与述评，着重剖析了现有算法的局限性，并在此基础上，前瞻性地指出了未来研究的改进方向，为算法在工业场景中的优化提供参考方案。

第 2 章 PCB 组件检测研究相关技术及理论

鉴于对 PCB 表面元件检测技术现有研究态势的考察，本章旨在阐述 PCB 表面元件检测的相关理论基础。主要包括 PCB 表面组件研究、深度学习理论基础、目标检测模型的演进历程、实验准备以及实验评价指标等方面，为后续的 PCB 表面元件检测研究提供理论支撑与数据保障。

2.1 PCB 表面组件研究

2.1.1 PCB 制造工艺

PCB 作为各类电子设备中不可或缺的关键组成部分，在其制造过程中需经历一系列复杂的工艺流程，图 2.1 展示了 PCB 的主要生产流程。可以看出 PCB 制造工艺十分繁琐，蚀刻好的电路板要进行第一次的检测和测试，确保线路能连通无短路断路现象，才能够装贴元器件。




图 2.1 卷积神经网络结构图

PCB 组件的检测贯穿设计、制造和组装全流程。虽然 PCB 的制造工艺虽然已高度成熟，但在实际生产中可能会有机器故障、人员疏忽等因素影响，将会直接影响电路板的质量和可靠性。检测可以避免焊接缺陷，如虚焊、短路等，确保每个元器件正确安装，防止后续故障。同时，组件检测还能帮助发现元器件的错件、反贴等问题，这些都是生产过程中常见的问题。

2.1.2 PCB 表面组件分析

PCB 在产生过程中产生的安装错误，如元器件的错件等，早期检测出问题可以避免后期的维修成本，减少废品率，这对于大规模生产来说尤其重要，本研

究对常见的 PCB 表面组件进行分析。具体常见表面元器件组件功能及尺寸如表 2.1 所示。

表 2.1 PCB 常见表面元器件分析

元器件类型	图片示例	常见尺寸	元器件功能
电阻 (Resistor)		2.0 * 1.25 (mm)	电阻器用于限制电流的流动，依靠其电阻值与电流产生的电压降相对应。它用于调节电路中的电流大小、分压、稳定电路或保护其他元器件。
电容 (Capacitor)		2.0 * 1.25 (mm)	电容器用于储存电能，并能在电路中充放电。它通过电场存储能量并用于滤波、耦合、解耦、平滑直流电源等。
二极管 (Diode)		2.7 * 5.2 (mm)	二极管是一个单向导电器件，只允许电流在一个方向流动。它的主要作用是整流、保护、调制信号等。
集成电路 (Integrated Circuit)		5.0 * 6.0 (mm)	集成电路是将多个电子元器件（如晶体管、电阻、电容等）集成在一块芯片上的电子元件。它执行复杂的电路功能，可以是放大、逻辑运算、信号处理等。
电感器 (Inductor)		1.6 * 0.8 (mm)	电感器利用磁场的变化来储存和释放能量。当电流通过电感器时，会在其周围产生磁场，电流变化时会感应出反向电动势，阻碍电流变化。电感器主要用于滤波、振荡和储能等。
晶体管 (Transistor)		2.9 * 1.3 (mm)	晶体管是一种半导体器件，具有放大和开关作用。它可以通过微小的输入信号控制较大的输出信号。晶体管的基本作用是电流放大、开关控制或信号处理。

2.1.3 PCB 表面组件检测存在的问题

目前看来，对于自动化 PCB 组件检测任务来说，其挑战可能存在于以下几个方面：

(1) PCB 组件尺寸小、存在低类间方差

从上面的表格尺寸中我们可以看出 PCB 表面装贴的元器件组件较小，在整体的图片中占的面积就相对较小，对于神经网络而言，组件包含的有效信息有限，模型对微小组件特征的学习能力存在局限性，这些因素可能导致检测模型在识别过程中忽视这些信息特征，无法全面准确地检测所有小目标。目标的密集和离散程度取决于具体的设计，分布越是不均匀，对目标检测算法要求就越是更高。这种情况会降低模型在组件检测方面的性能表现，从而影响整体检测结果的准确度和可靠性。

我们也能看到组件有的十分类似，存在低类间方差。低类间方差表现在一些最常见的元件，例如电阻和电容，在特定的照明条件下也可能出现相似的情况，这就是低类间方差，即组件相似。很可能会出现错检、漏检的现象，这在工业产品控制中将带来严重的后果。

（2）有限的 PCB 组件数据集

对于有限的数据量的挑战而言，一张 PCB 板需要由有一定电路知识的学者对图像进行标记工作，每张 PCB 电路板上的组件个数相对于其他任务而言较多，标记工作需要一定的时间和成本。同时 PCB 硬件保障目前是一个类别数量较多、数据集相对较少的领域。

（3）强噪声干扰

由于工业现场环境的复杂性，在 PCB 图像进行采集的过程中，容易受多种环境因素及输入设备性能的制约。例如，光照条件的变动、环境温度的波动、生产线传送装置的振动、成像设备自身的抖动以及可能出现的帧丢失等现象，均会导致所获取的 PCB 图像中含有较强的噪声干扰信息，从而显著增加了 PCB 组件检测的难度与复杂性。

2.2 卷积神经网络理论研究

2.2.1 卷积神经网络

卷积神经网络（Convolutional Neural Networks, CNN）作为仿生视觉机制的特征学习架构，通过层次化特征抽取机制实现了端到端的表示学习。区别于传统手工特征工程，该网络采用参数共享的卷积核进行局部感受野扫描，借助反向传播算法自适应调整卷积核参数。典型 CNN 架构由特征提取模块（含卷积层、非线性激活层、池化层）与分类决策模块（全连接层与 Softmax 层）构成，完整的卷积神经网络如图 2.2 所示。




图 2.2 卷积神经网络结构图

2.2.2 输入层

CNN 的输入层主要承担着对输入数据进行初步预处理的功能，其目的是将数据转化为适合 CNN 直接处理的格式。这一预处理过程不仅能够优化图像处理的结果，还能显著缩短网络的训练时间，加快网络的收敛速度，从而有助于获得更为理想的效果。通过这种预处理，输入层为后续的卷积运算和特征提取奠定了基础，对整个 CNN 的性能提升起到了关键作用。

2.2.3 卷积层

卷积层是卷积神经网络架构中的核心组成部分，其主要功能是通过卷积运算来提取图像的多样化特征。该层的运作机制可以类比作为一种特殊的滑动窗口技术，但其独特之处在于利用滤波器（即卷积核）在图像上进行系统性的扫描。在这个过程中，卷积核与图像的每个局部区域进行点积运算。常用的卷积核尺寸包括 3×3 、 5×5 以及 7×7 等。通过这种连续的卷积和点积操作，生成的特征图会逐渐缩小，从而能够捕捉到更加精细和抽象的图像特征。这种机制使得卷积层能够有效地提取和表示图像的层次化特征信息。具体的卷积计算公式如 (2.1) 所示。

$$F(x, y) = \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} P(x-i, y-j) K(i, j) \quad (2.1)$$

其中 $F(x, y)$ 代表的是经过一次卷积过后所得到的特征图， $P(x, y)$ 代表的是 $x \times y$ 原图像， $K(i, j)$ 代表的是 $M \times N$ 的卷积核。

图 2.3 所示为一个输入大小为 $(4, 4)$ ，卷积核大小为 $(3, 3)$ ，输出大小为 $(2, 2)$ 的一个二维卷积的计算流程。




图 2.3 卷积计算流程示例图

从图示中可以观察到,卷积操作会导致特征图的尺寸减小,不同于原始图像。然而,在某些特定任务中,我们可能对特征图的维度有特定要求。因此,在进行卷积运算之前,我们通常会对原始图像实施填充(padding)处理,一种常见的方法是在图像周围添加零值。通过一系列的填充策略,我们能够获得符合预期尺寸的特征图。除了在卷积操作的空间维度控制中,滑动步进值(stride)的配置是除填充外另一关键调节机制。该参数实质定义了卷积核在特征平面上滑动的采样间隔,其数值设定直接影响输出特征映射的空间分辨率。特别需要指出的是,当采用较大步进值时,将引发特征图的空间下采样效应,具体表现为输出维度遵循式(2.2, 2.3)所示规律。

$$W_F = \frac{W - F_w + 2P}{S} + 1 \quad (2.2)$$

$$H_F = \frac{H - F_h + 2P}{S} + 1 \quad (2.3)$$

在此公式中, W 和 H 分别为输入到网络中的图像的宽度和高度。经过卷积运算后生成的特征图,其维度以宽度 W_F 和高度 H_F 度量。卷积核的尺寸由其宽度 F_w 和高度 F_h 定义,填充量 P 和卷积步长 S 也是影响卷积输出尺寸的关键参数,这些参数共同决定了卷积操作的输出尺寸。

2.2.4 池化层

池化层(Downsampling Layer)在卷积神经网络中一般是用来对输入进行下采样操作的,所以又称之为下采样层,通常在经过连续的卷积之后会穿插池化层。该层的主要目的是用来对感受野的特征进行采样,提取出具有代表性的特征信息输入到后续网络中,减小后续特征图的尺寸从而减少网络中的参数量。它不仅能

够有效防止模型出现过拟合现象,还能够提高计算效率,从而优化整体网络性能。在实际应用中,最为常见的池化方法主要分为两类:最大池化(Max Pooling)和平均池化(Average Pooling)。这两种方法各有其特点和适用场景,为不同的网络结构和任务提供了灵活的选择。

第一种是最大池化,最大池化操作的核心在于执行局部区域内的特征强度筛选。其实现流程包含三个关键步骤:(1)定义空间采样窗口尺寸(如 2×2 网格);(2)按照预设步进值(如 $S=2$)在输入特征矩阵上进行滑窗遍历;(3)在每个采样窗口覆盖的局部感受野内,选取激活强度最大的神经元响应值作为输出。如图2.4所示,当 6×6 的输入特征矩阵采用 2×2 采样窗口配合 $S=2$ 的配置时,输出维度精确缩减为 3×3 ,此时每个输出单元对应输入空间中最大激活值的坐标位置记录,该机制在反向传播过程中形成稀疏梯度分布。




图 2.4 最大池化层示意图

第二类为平均池化:该方法通过计算特定区域内像素值的算术平均值来实现。其具体实施过程与最大池化相类似,但在最终输出阶段,它采用所选区域内像素值的平均数作为结果。这种方法在保留图像整体特征的同时,能够有效降低空间维度和计算复杂度,如下图 2.5 所示。




图 2.5 平均池化层示意图

2.2.5 全连接层

全连接层作为 CNN 的末端组件,负责将多维特征张量压缩为低维语义编码。该层通过权重矩阵实现特征空间的全映射,所得特征向量经 **Softmax** 函数转化为类别概率分布。其结构特性体现为相邻层间的完全权重互联——当前层每个神经元接收前层全部单元的输出加权和,经非线性激活后传递至后续层级。中间隐含层通过多级此类变换,逐步提取数据的深层抽象模式。

但是该结构的参数密集特性引发显著问题:当处理高维输入时,权重矩阵维度呈现平方级增长,导致模型易陷入过参数化困境。此外,严格的输入尺寸约束限制了网络的灵活性。针对这些问题,当前主流方案采用全局平均池化替代传统全连接层,通过空间维度逐通道均值计算实现参数高效压缩。对比实验表明,该策略在维持分类精度的同时显著提升模型泛化能力,如图 2.6 所示的结构对比可直观反映两者的参数密度差异。




图 2.6 全连接层示意图

2.2.6 输出层

在卷积神经网络的结构设计中，分类层作为全连接层的后续处理模块，承担着特征空间到决策空间的映射职责。该模块通过非线性变换函数（如 Softmax）对前层输出的高维特征张量进行概率化重构，生成与预设类别维度相匹配的分布向量。此概率分布不仅表征输入样本与各类别的隶属度关系，同时为网络提供可微分的决策依据，模型最终通过比较各类别概率权值实现预测结果的确定性输出。

在卷积神经网络中，激活函数扮演着至关重要的角色。其核心功能在于特征选择，即保留对模型有益的特征，同时抑制冗余或无用的特征。激活函数的引入赋予了网络非线性建模能力。若缺乏激活函数，网络将仅能表达线性映射，此时无论网络深度如何增加，其本质上等同于单层网络，这不仅导致大量冗余计算，还会严重损害模型的性能。目前，广泛应用的激活函数包括 Sigmoid 函数、双曲正切函数（Tanh）、修正线性单元（Rectified Linear Unit, ReLU）、带泄露的修正线性单元（Leaky ReLU）以及 Swish 函数等。

（1）Sigmoid 激活函数

Sigmoid 激活函数的表达式（2.4）所示，从 Sigmoid 激活函数的公式中可以看出，Sigmoid 激活函数具有连续性和单调性，其函数图像呈中心对称形态。

$$f(x) = \frac{1}{1+e^{-x}} \quad (2.4)$$

Sigmoid 激活函数具有特定的优势与局限性。其优势在于：首先，Sigmoid 函数在整个定义域内连续可导，这一特性有利于进行梯度计算；其次，Sigmoid 函数的输出值域为 (0, 1)，便于构建概率模型并进行前向信息传递。然而 Sigmoid 函数也存在一些固有缺陷：首先，当输入值过大或过小时，Sigmoid 函数会进入饱和区，即函数曲线趋于平缓，导致梯度趋近于零。这种梯度消失现象会阻碍反向传播过程，使得权重更新停滞。其次，Sigmoid 函数为非零中心函数，其输出均为正值。这导致在反向传播过程中，梯度更新方向被限制，要么全为正，要么全为负，从而降低了参数优化的效率。最后，Sigmoid 函数涉及指数运算，这在计算上具有较高的复杂度，增加了计算资源的消耗。

（2）Tanh 激活函数

Tanh 激活函数的表达式如（2.5）所示，Tanh 激活函数具有以零为中心的特性，其输出值域被限定在 (-1, 1) 区间内。这一特性解决了 Sigmoid 函数存在的非零中心化问题，从而提升了 Tanh 函数相对于 Sigmoid 函数的效率。然而，Tanh 函数的一个显著缺陷在于，当输入值处于饱和区域时，其梯度趋近于零。这种现象会导致梯度无法有效反向传播，进而阻碍模型参数的更新过程。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.5)$$

(3) ReLU 激活函数

ReLU 激活函数的表达式如 (2.6) 所示, ReLU 激活函数可被视为一种分段线性函数。当输入值小于零时, 函数输出为零; 当输入值大于或等于零时, 函数输出与输入值相同。

$$f(x) = \max(0, x) \quad (2.6)$$

ReLU 激活函数的优点包括梯度非饱和性: ReLU 在正值区间内梯度恒为 1, 有效避免了梯度饱和现象, 从而缓解了传统激活函数 (如 Sigmoid 和 Tanh) 在深度网络中易出现的梯度消失问题, 保证了梯度在反向传播过程中的有效传递和参数更新。其次 ReLU 激活函数具有稀疏激活特性: ReLU 将负输入值映射为零, 诱导了网络激活的稀疏性。在深度学习中, 稀疏特征表示被认为具有更强的鲁棒性, 有助于降低模型过拟合的风险。同时 ReLU 激活函数有着计算上的高效性: ReLU 的计算仅涉及阈值比较和取最大值操作, 实现简单, 计算效率显著高于涉及指数运算的激活函数。

ReLU 激活函数的局限性在于: 当输入为负时, 输出恒为零, 导致相应的神经元处于非激活状态, 权重无法得到更新。这种现象被称为“神经元死亡”, 即部分神经元在训练过程中永久失活, 无法对网络的信息处理做出贡献。

(4) Leaky ReLU 激活函数

Leaky ReLU 函数的数学表征如式(2.7)所示, 其在正区间与标准 ReLU 保持完全一致的线性响应特性。该改进型激活函数的核心创新体现在负值域处理策略: 当输入信号低于激活阈值时, 不再进行硬性截断操作, 而是通过引入可调斜率参数 α 实现梯度保留, 具体表现为输入值与预设系数的线性组合输出。这种设计有效缓解了传统 ReLU 因零梯度导致的神经元坏死问题。

$$f(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases} \quad (2.7)$$

Leaky ReLU 函数针对传统 ReLU 的负值处理缺陷进行改进, 采用非对称激活机制缓解神经元失活问题。该函数在负向输入区间设置微小正斜率系数, 确保反向传播过程中梯度信息得以有效保留, 维持了参数更新的稳定性。该方法完整保留了 ReLU 在正向区间的稀疏激活特性, 同时规避了零梯度现象。但需注意, 该激活策略在处理正负特征时存在激活响应不对称性, 可能影响特征空间分布的均衡性。

(5) Swish 激活函数

Swish 激活函数的表达式如 (2.8) 所示。Swish 激活函数与 ReLU 激活函数均呈现无上界的特性, 因此有效避免了梯度饱和现象的发生。同时, Swish 函数

具有下界，有助于增强模型的正则化效应。此外，Swish 函数全域可导，这一性质显著提升了模型训练的可行性与效率。

$$f(x) = x * \text{sigmoid}(ax) \quad (2.8)$$

2.3 目标检测算法概述

计算机视觉领域中的目标识别技术主要包含两种实现路径。两阶段方法首先通过区域建议网络生成潜在目标区域，再对每个建议区域进行特征提取与分类识别，最后采用回归模块修正边界框坐标。单阶段方法则直接在特征图上进行密集预测，同步完成目标定位与类别判断，省去中间建议框生成环节。从技术发展历程看，两阶段架构凭借分步细粒度处理在检测精度方面保持较高识别准确率，但存在计算资源消耗较大的不足。单阶段方案早期受限于特征表达能力，虽具有实时处理优势却难以兼顾小目标检测效果。随着特征融合技术与损失函数设计的持续优化，当前单阶段检测器在保持运算效率优势的同时，其检测精度已实现突破性提升，逐步缩小与两阶段方法的性能差距。下文将详细介绍两种目标检测算法。

2.3.1 基于候选窗口的两阶段目标检测算法

在基于候选区域的两阶段目标检测算法演进过程中，Girshick 团队于 2014 年提出的 R-CNN^[41]具有里程碑意义。该模型采用选择性搜索算法生成约 2000 个候选区域，通过独立卷积神经网络（CNN）对每个候选框进行特征提取，结合支持向量机（SVM）分类器完成目标识别，并采用边界框回归算法优化定位精度。然而该框架存在显著缺陷：候选区域重叠导致特征重复计算（单图检测耗时约 53 秒），且候选框的归一化裁剪造成图像形变。

针对上述问题，He 等人在 2015 年提出的 SPP-Net^[42]实现重要突破。其创新性地在 CNN 末端的全连接层前插入空间金字塔池化层（SPP），通过多尺度池化操作（4×4、2×2、1×1）生成固定维度特征向量，消除输入图像尺寸限制，使特征提取速度提升 24 倍。同年 Girshick 团队推出 Fast R-CNN^[43]，其核心改进包括：采用 ROI 池化层替代 SPP 层，实现更高效的特征采样；将分类与回归任务整合为多任务损失函数，通过端到端训练提升参数优化效率；引入 Softmax 分类器替代 SVM，使检测耗时缩短至 0.3 秒/图像。

尽管 Fast R-CNN 相较于 R-CNN 已经显著减少了计算量，但其仍依赖于选择性搜索算法，存在效率较低、速度较慢等问题。Ren 等人在 2015 年末提出的 Faster R-CNN^[44]实现质的飞跃。该模型首次引入区域建议网络（RPN），通过锚点机制生成高质量候选区域。RPN 与检测网络共享卷积特征，使候选框生成耗

时从 2 秒/图降至 10 毫秒/图，整体检测速度达到 5FPS。其采用"交替训练"策略，通过四步训练法实现 RPN 与 Fast R-CNN 的联合优化。

Dollár 团队 2017 年提出的 Mask R-CNN^[45]在 Faster R-CNN 基础上拓展出实例分割能力。关键改进包括：设计双线性插值 ROI Align 层替代 ROI Pooling，将特征图与原始图像像素对齐误差降低 60%；新增并行掩膜预测分支，通过 FCN 网络生成像素级分割结果；采用解耦式训练策略，使检测与分割任务相互促进。该框架在 COCO 数据集上实现 35.7%的平均检测精度，较基线模型提升 9.1 个百分点。

表 2.2 基于候选区域的两阶段目标检测算法的优缺点及适用场景

检测算法	优点	缺点	适用场景
R-CNN ^[41]	首次将 CNN 引入目标检测；在候选区域独立提取特征，分类精度较高	特征重复计算严重；存储消耗大(需保存所有候选特征)；训练流程复杂	目标检测
SPP-Net ^[42]	支持任意尺寸输入；通过空间金字塔池化共享卷积特征，减少特征计算量	仍需独立训练 SVM 分类器；ROI 池化导致特征错位；多尺度池化增加计算复杂度	目标检测
Fast R-CNN ^[43]	实现端到端训练；采用 ROI 池化统一特征维度；分类与回归联合优化提升模型收敛效率	仍依赖选择性搜索；池化操作损失空间细节；小目标易被过度下采样	目标检测
Faster R-CNN ^[44]	引入 RPN 网络实时生成候选框，特征共享使检测速度提升；端到端优化	RPN 锚点机制对小目标覆盖不足；候选框与检测网络耦合度高；多任务训练难度较大	目标检测
Mask R-CNN ^[45]	新增掩膜分支实现实例分割；RoI Align 消除特征偏移；支持多任务协同学习	掩膜预测使计算量增加 40%；需像素级标注数据；整体推理速度降低至 3FPS	目标检测、实例分割

2.3.2 基于回归的单阶段目标检测算法

相较于两阶段检测架构，单阶段目标检测模型通过结构重构将区域特征抽取

与定位回归融合为统一过程,在单次前向传播中同步完成目标分类与空间坐标回归,计算效率得到数量级提升。该类算法的典型代表包含实时性优异的 YOLO (You Only Look Once) 架构和具有多尺度感知特性的 SSD (Single Shot MultiBox Detector) 模型。

2016 年,Redmon 团队开创性提出首个端到端单阶段检测框架 YOLO^[46]。该模型受 GoogLeNet 网络拓扑启发,采用均匀分割策略将输入图像离散化为 $S \times S$ 的单元网格。每个网格区域经卷积模块处理后,并行执行三项核心任务:中心点概率估计、包围盒参数回归及多类别判别。为优化检测结果,系统通过非极大抑制算法 (Non-Maximum Suppression, NMS) 剔除冗余预测框,保留置信度最优的检测结果。它的主要算法流程为:输入图像馈入神经网络后,网络会将图片分成 $C \times C$ 个网格,每个网格单元被输入卷积神经网络进行处理,独立预测出每个图像块属于各个类别 (总共有 M 个类别) 的概率,将其记作 $\text{Pr}(\text{Class}_i|\text{Object})$ 。如果某个物体的中心点在某个网格中,那么该网格后续就负责预测该物体。其次,在每个网格周围生成 B 个边界框 (Bounding Box)。每个边界框包含五个预测值:中心点坐标 (x,y) ,宽高 (w,h) 以及置信度这五个值,其中置信度的值是由 (2.9) 计算得到的。

$$\text{Confidence} = \text{Pr}(\text{Object}) * \text{IOU}_{\text{pred}}^{\text{truth}} \quad (2.9)$$

该置信度指标的计算逻辑可表述为:当候选框内存在有效目标时, $\text{Pr}(\text{Object})$ 取值为 1, 否则置零, 其中 $\text{IOU}_{\text{pred}}^{\text{truth}}$ 参数表示预测区域与标注框的空间重叠度量。当两者的空间分布完全匹配时, $\text{IOU}_{\text{pred}}^{\text{truth}}$ 达到理论最大值 1, 反之趋近于 0。YOLOv1 框架的提出在实时检测领域实现了突破性进展,其单阶段处理机制为后续算法的实时性优化确立了基础范式。然而受限于单元网格的单一类别判定机制,当处理高密度小目标场景时,易发生网格单元内多目标共存现象,引发漏检和误检概率的同步上升。这种设计特性使得原始 YOLO 架构在微小目标检测任务中存在显著的技术瓶颈。

针对单阶段检测器的性能瓶颈, Liu 团队于 2016 年提出了 SSD^[47] 目标检测模型, 该模型在 Faster R-CNN 锚框机制基础上, 构建了覆盖不同感受野的特征金字塔, 通过卷积网络的多层级特征图联合预测目标位置与类别。实验表明, 其小目标检测任务中的平均精度较 YOLOv1 提升约 23%, 尤其在低分辨率图像处理中展现出更强的空间敏感性。

为解决初代模型定位精度不足问题, Redmon J 等人于 2017 年提出了 YOLOv2^[48] 目标检测算法。该算法采用了一系列改进措施包括: 设计了 19 层的 Darknet 主干网络增强特征提取能力; 引入批量归一化提升训练稳定性; 构建高分辨率分类器改善细粒度识别; 采用 K-means 聚类生成适配数据分布的锚框参数;

创新直接坐标预测机制降低定位误差；实施多尺度训练策略增强模型鲁棒性。这些改进使 COCO 数据集上的 mAP 值从 63.4% 提升至 78.6%。

Redmon J 等人在 2018 年对 YOLOv2 的基础架构进行了优化，提出了 YOLOv3^[49]。在前代架构基础上，该版本构建 53 层深度残差网络，通过跨层连接增强梯度传播效率。创新性融合特征金字塔技术，建立“检测头-特征层”动态匹配机制，使小目标召回率提升 19.2%。采用逻辑回归替代 Softmax 分类，有效缓解多标签场景下的预测冲突问题。

Bochkovskiy A 等人于 2020 年在 YOLOv3 算法的基础上进一步改进，提出了 YOLOv4^[50]。通过跨阶段特征复用技术重构主干网络，CSPDarknet-53 使计算密度降低 40% 的同时保持特征表达能力。在特征融合模块引入双向参数聚合路径，构建空间-通道双重注意力机制。改进后的模型在 VisDrone 密集小目标数据集上取得突破性进展，较 YOLOv3 提升 17.8% 检测精度。

Redmon J 等人于 2020 年在 YOLOv4 架构的基础上进行了优化，提出了 YOLOv5 模型^[51]。该版本开创性地将工业级优化策略引入检测框架：Mosaic 数据增强技术使训练数据利用率提升 3 倍；自适应锚框计算实现参数动态优化；Focus 切片操作有效平衡计算量与特征保留率。这些改进使模型在嵌入式设备上的推理速度达到 153FPS。

Ge Z 等人于 2021 年对 YOLOv5 模型进行了改进，提出了 YOLOX 模型^[52]。通过解耦分类与回归任务分支，采用无锚框预测机制简化检测流程。引入 SimOTA 动态样本匹配策略，使正负样本分配效率提升 60%。在自动驾驶场景测试中，其误检率较 YOLOv5 降低 34%。

Wang C Y 等人于 2022 年提出了 YOLOv7 算法^[53]，该算法对 YOLOv5 和 YOLOX 进行了改进，融合模型重参数化技术与动态网络架构，提出的 ELAN（Efficient Long-range Aggregation Network）模块使长程特征关联效率提升 45%。通过辅助监督头与跨尺度搜索策略，在无人机航拍图像检测任务中创下 83.4% 的 mAP 记录。

2023 年，Ultralytics 公司又发布了更为先进的 YOLOv8，在精度和检测速度上进一步有所提升，在后面的章节中会介绍其基本架构^[54]。YOLOv10 是 2024 年由研究团队提出的一种改进型实时目标检测模型，旨在解决 YOLO 系列在小目标检测、模型轻量化及多尺度特征融合中的局限性^[55]，在 COCO2017 数据集上，YOLOv10 的 mAP@0.5 达到 86.2%，较 YOLOv8n 提升 2.8%，推理速度达 120 FPS。

随着一阶段检测网络的持续发展，其检测精度已达到并超越了二阶段检测网络，同时其检测速度也显著快于二阶段检测网络。然而，PCB 表面组件的种类

繁多、形态复杂且尺寸较小，这给 PCB 表面组件的检测带来了极大的挑战。因此，现有网络仍需进一步优化和改进。

2.4 PCB 组件检测算法评价指标

PCB 组件检测本质上是属于目标检测中的一个特例，下面介绍几种目标检测中常见的评价指标，分别是精确率（Precision）、召回率（Recall）、平均精度（Average Precision）、平均精度均值（mean Average Precision, mAP）、PR 曲线（Precision-Recall curve）和检测速度。

（1）精准率和召回率

在目标检测任务中，精确率和召回率是衡量模型性能的重要指标。精确率定义为模型预测正确的正样本数量与模型预测的所有正样本数量的比值。通常，当预测框与真实标注框的交并比（IoU）大于或等于 0.5 时，认为该预测框预测正确。召回率定义为模型预测正确的正样本数量与实际总的正样本数量的比值。为进一步阐述计算过程，考虑以下情形：假设数据集中存在 M 个正样本和 N 个负样本。模型将 m 个正样本正确预测为正样本，而将其余 $(M-m)$ 个正样本错误预测为负样本；同时，模型将 n 个负样本正确预测为负样本，而将其余 $(N-n)$ 个负样本错误预测为正样本。基于上述情形，可以定义以下术语：真阳性（True Positive, TP）：被模型正确预测为正样本的正样本数量，即 m 。假阴性（False Negative, FN）：被模型错误预测为负样本的正样本数量，即 $(M-m)$ 。真阴性（True Negative, TN）：被模型正确预测为负样本的负样本数量，即 n 。假阳性（False Positive, FP）：被模型错误预测为正样本的负样本数量，即 $(N-n)$ 。

在获取上述四个关键指标后，即可着手计算精确率与召回率。二者的计算公式如（2.10）和（2.11）所示：

$$Precision = \frac{TP}{TP+FP} = \frac{m}{m+N-n} \times 100\% \quad (2.10)$$

$$Recall = \frac{TP}{TP+FN} = \frac{m}{m+M-m} \times 100\% \quad (2.11)$$

F1 分数（F1-score）常被用作评估模型精度的指标。它可以被视为模型精确率和召回率的调和平均数，其值域为 $[0, 1]$ 。F1 分数越高，表明模型的性能越优。它的表达式如（2.12）所示：

$$F_1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (2.12)$$

（2）PR 曲线和 AP 值

精确率-召回率曲线，简称 PR 曲线，是一种可视化工具，用于评估模型在不

同阈值下的性能。该曲线以召回率（Recall）为横轴，精确率（Precision）为纵轴绘制而成。PR 曲线直观地展现了模型的召回率与精确率之间的权衡关系，有助于研究者选择合适的阈值，以平衡模型的查全率和查准率，其图像如 2.7 所示。

平均精度简称 AP 是另一种评估模型性能的指标。尽管 PR 曲线能够清晰地反映单个检测器的性能，但在比较多个检测器时，尤其当它们的 PR 曲线不相交时，直接比较性能较为困难。此时，AP 值提供了一种量化的比较方法。AP 值本质上是 PR 曲线下的面积，通过计算该面积，可以对不同检测器的性能进行定量比较。AP 值越大，表明检测器的性能越优越。AP 值的计算公式如式（2.13）所示。平均精度均值简称 mAP 是目标检测算法性能评估的核心指标。mAP 的计算过程如下：首先，针对每个类别分别计算其平均精度 AP，然后，对所有类别的 AP 值计算算术平均值，得到最终的 mAP 值。mAP 值的计算公式如式（2.14）所示。mAP 综合衡量了算法在所有类别上的检测精度和召回率，其值越高，表明算法的整体检测性能越好。

$$AP = \int_0^1 p(r)dr \quad (2.13)$$

$$mAP = \frac{1}{n} \sum_{i=1}^n AP_i \quad (2.14)$$




图 2.7 PR 曲线

在评估不同检测器的性能时，一种直观且常用的方法是比较其各自的精确率-召回率曲线。检测器的性能优劣可以通过 PR 曲线所覆盖的面积大小来衡量，面

积越大,表明该检测器在不同阈值下综合考虑精确率和召回率的能力越强,即整体性能越优异。

(3) 检测速度

在实际应用场景中,PCB 组件检测技术具有广泛的应用价值,并对检测的时效性有特定需求。因此,评估 PCB 组件检测算法的性能时,检测速度是不可或缺的考量因素。若某种 PCB 组件检测算法以牺牲检测速率为代价来获取高精度均值,则该算法难以在实际生产环境中部署应用,其价值将局限于理论研究层面。衡量检测速度的常用指标为帧率(FPS),即每秒可处理的图像数量。FPS 值越高,表明检测器的检测速度越快。其表达式如(2.15)所示:其中 M 表示模型处理的图片数量总和, S 为模型对所有的输入图片检测所消耗的时间总长。

$$FPS = \frac{M}{S} \quad (2.15)$$

2.5 本章小结

本章节首先介绍了 PCB 的制造、PCB 表面组件种类的分析 and 组件检测中的难点,为后文的研究做铺垫。然后介绍了卷积神经网络的核心组成部分,详细阐述了输入层、卷积层、池化层、全连接层和输出层的作用机理与技术细节。并针对目前深度学习在目标检测任务领域中的研究概述,介绍了基于候选区域的双阶段目标检测算法与基于回归的单阶段目标检测算法两大类,并分析了优缺点和适用的场景。最后,本章还系统地梳理了用于评估 PCB 组件检测算法性能优劣的关键指标。

第 3 章 基于 YOLOv8 的 PCB 组件检测算法研究

3.1 引言

PCB 作为电子工业的基础组件，其质量对下游产业如通信设备、半导体制造和航空航天产品性能具有至关重要的影响，可见 PCB 的硬件保障是一项不可或缺的环节。对 PCB 组件精确地进行检测是保障下游产品质量的关键环节也是控制成本的关键，因此 PCB 表面组件小目标的检测是一项具有重要意义的研究课题。然而现阶段的 PCB 缺陷检测技术仍面临诸多挑战如：组件目标尺寸较小、占总体面积占比小，目标与 PCB 背景对比度低、容易受到光照影响，组件目标分布无规律等问题。传统检测方法在速度、精度和可扩展性上面临瓶颈，难以适应现代供应链的复杂环境。因此，开发一个能够精确识别和定位 PCB 组件的模型显得十分重要，同时也要兼顾检测的速度，目前 YOLO 系列的方法在目标检测上表现较好，且经过实验发现 YOLOv8n 效果最好，故本章基于精度与检测速度兼具的 YOLOv8n 网络进行 PCB 组件的检测任务。

3.2 YOLOv8 目标检测算法研究

以 YOLO 系列算法为核心的单阶段目标检测模型，核心是直接采用卷积神经网络进行特征提取。该模型在预测特征图上并行生成边界框，并同步进行分类与回归作业，模型实现了从图像输入到预测结果的全流程端到端作业。此设计范式支持对整个神经网络进行全局优化，进而增强了目标检测的准确性与效能指标。相较于 R-CNN 等双阶段检测框架的处理流程，YOLO 系列通过端到端推理机制实现目标空间定位与语义判别的同步完成。一体化处理技术成功减少了精确定位与精确分类两个阶段间的误差累加。此外大规模目标检测任务中，YOLO 系列算法以其高效性脱颖而出，检测速度明显增强，训练与测试阶段均显现高效性。2023 年 Ultralytics 公司发布了 YOLO 系列的新版本——YOLOv8^[54]，是当时最好的 YOLO 模型。YOLOv8 在前代版本成功的基础上，迈向了新的阶段，推出了一系列新功能及优化手段，本研究的目的是为了明显提升模型的性能、灵活度及运作效率。

本章将详细阐述 YOLOv8 算法的基础理论，为读者提供全面的知识体系，本节全面剖析了该算法的原理与技术特性。本章所采用的算法，以 YOLOv8 为

研究起点，本文将分别剖析 YOLOv8 算法的网络架构与损失函数。

3.2.1 网络结构

YOLOv8 网络结构由四个关键部分组成：输入端、主架构、颈部架构及输出检测端。如图 3.1 所示，该图详细展示了 YOLOv8 的网络架构。




图 3.1 YOLOv8 网络模型图

在输入层，对原始图像进行预处理操作，将其统一调整为 640×640 像素分辨率的 RGB 格式图像。为提升模型的泛化能力和鲁棒性，丰富数据集、增加目标数量及图像数据的多样性，YOLOv8 采用了四种主要的数据增强技术：马赛克增强（Mosaic）、混合增强（Mixup）、随机空间扰动（Random Perspective）和 HSV 颜色空间扰动（HSV Augmentation）。即模型集成了在线数据增强机制。在线数据增强的定义为：在模型训练的每个迭代周期内，对从原始数据集中抽取的样本执行即时的数据变换操作，从而生成新的、具有多样性的训练样本，并将其用于当前批次的模型参数更新。具体而言，该模型在训练过程中，会动态地对数据集应用一系列随机变换，实现数据的实时增强。但是该技术手段带来的数据增强效果仅在原本的数据集中进行变换拼凑，最好的方法还是收集尽可能多的数据样本。

主干网络主要承担提取目标特征的任务，将特征导引至颈部及头部网络。Backbone 由卷积模块（CBS）、C2f 结构和空间金字塔池化模块（SPPF）组成。YOLOv8 的主干网络支持多尺度特征融合，这意味着它能够从不同层次提取的特征图中结合信息，这种方法在处理不同尺寸的目标时表现尤为出色，尤其是在复

杂场景中，能够有效提高检测的准确性和鲁棒性。CBS 模块由一个二维卷积层（Conv2d）、一个批归一化层（Batch Norm2d）和一个 SiLU 激活函数构成。该模块的主要功能是提取特征并对特征图进行规整。C2f 结构借鉴了梯度流分流的分流思想，对串联的瓶颈模块（Bottleneck）实施连接操作，对模块的架构进行了调整。该设计成功阻断了网络深度加深时收敛性能下降的演变。网络结构的优化与轻量化，C2f 结构两者兼得，能够搜集到丰富的梯度流资料，由此 YOLOv8 模型的整体性能明显升级。SPPF 模块的主要用途是融合不同尺度的特征，多尺度问题已有效解决，成效显著算法检测的精确性大幅上升。

Neck 模块采用特征金字塔网络（FPN）与路径聚合网络（PAN）的融合架构，强化了特征在不同维度上的融合，提升了模型在多尺度上的语义表征能力和定位精度。

Head 模块采纳了现行的主流解耦头架构（Decoupled Head）。本架构成功将分类与回归任务解耦，即将定位与分类分为两个分支，分别通过两个独立的分支进行处理，舍弃置信度预测，加速模型收敛并提高检测精度。Head 模块基于前述模块提取的特征，预测目标的类别与位置信息，生成最终的预测输出。

综上所述 YOLOv8 凭借其卓越的灵活性在业界独树一帜，既追求目标检测的高精度，又兼顾实时性的重要需求，其实际应用及工业工程领域的价值已获得广泛的认可该算法在目标检测领域内，因其流行性及高效性，成为首选。下面介绍两个 YOLOv8 中在先前网络上最明显的改进部分，C2f 模块和 SPPF 模块以及头部的创新设计。

（1）C2f 模块

YOLOv5 中的 C3 模块的设计融合了 CSPNet（Cross Stage Partial Network）的分流策略与残差结构的思想。其核心组件为 C3 Block，该结构借鉴了 CSPNet 的分流理念，并在主分支梯度模块中集成了 Bottleneck 模块（即残差模块）。C3 Block 的堆叠数量由参数 n 控制，这意味着在不同规模的模型中， n 的取值会进行相应的调整，如图 3.2 所示。将 YOLOv5 的 C3 结构换成了梯度流更丰富的 C2f 结构，并对不同尺度模型调整了不同的通道数，就是 YOLOv8 中提出的 C2f 结构，如图 3.3 所示。




图 3.2 C3 模块




图 3.3 C2f 模块

我们从上图可以很容易地看出，C2f 模块的设计借鉴了 C3 模块及 ELAN 网络的架构思想。这种设计旨在确保 YOLOv8 模型在保持轻量化特性的同时，能够捕获更为丰富的梯度流信息。图中的 Split 操作，该操作针对具有特定维度（高度×宽度×输出通道数）的特征图，沿其通道维度进行等分处理。具体而言，即将原始特征图的输出通道数维度均分为两部分，从而产生两个新的特征图。这两个新特征图在高度和宽度维度上与原始特征图保持一致，但在输出通道数维度上，各自拥有原始特征图输出通道数的一半。

（2）SPPF 结构

SPPF（Spatial Pyramid Pooling Fast）是一种经过优化的池化层，其设计目标是通过多尺度特征提取来增强深度学习模型的性能。作为空间金字塔池化（Spatial Pyramid Pooling, SPP）的一种改进版本，SPPF 致力于在保持多尺度特征融合能力的同时，提升处理速度与效率。SPP 结构和 SPPF 结构如下图 3.4 和图 3.5 所示。与传统卷积神经网络对固定尺寸输入的约束不同，SPPF 能够处理任意尺寸的输入图像，相应的也就提高了模型的适应性。SPPF 通过在多个空间尺度上执行池化操作，实现了对不同尺寸目标特征的有效捕获，并显著提升了计算速度与效率。因此 SPPF 在目标检测、图像分类等计算机视觉任务中得到了广泛应用，并已成为增强特征表示和提升模型性能的关键技术。




图 3.4 SPP 空间金字塔池化层结构




图 3.5 SPPF 快速空间金字塔池化层结构

(3) 头部网络 (Head)

YOLOv8 的网络架构中，头部模块实现了显著的优化。具体而言，YOLOv8 摒弃了 YOLOv5 中采用的耦合检测头 (Coupled Head)，转而采用了解耦检测头 (Decoupled Head)。同时，目标检测机制也发生了根本性转变，由原先的基于锚点 (Anchor-Based) 范式过渡到无锚点 (Anchor-Free) 的形式，使得模型的检测不再受到锚框的限制。上述改进措施使得模型能够更有效地适应具有不同尺度和形态特征的目标，从而显著提升了整体检测性能。

从 YOLOv2 至 YOLOv5 系列模型持续采用耦合式检测头设计，其核心机制通过单层 1×1 卷积联合输出目标类别概率、边界框坐标及置信度参数。以 YOLOv5 为例如图 3.6 所示，网络采用一个 1×1 的卷积层，对各类别的概率、边界框的回归参数以及目标的置信度 (objectness) 进行同步预测。该架构将多任务预测集成于统一特征空间，虽保持了计算效率优势，但 YOLOX 研究团队通过

消融实验发现，分类与回归任务的联合优化存在特征干扰现象。研究显示这种耦合设计可能引发分类与定位任务的特征竞争，导致网络收敛速度降低。

而在 YOLOv8 算法的检测头部分，引入了一种创新性的解耦检测头结构，如图 3.7 所示。该结构通过双分支结构实现任务分离，分类分支独立处理目标类别概率分布，回归分支专注边界框坐标参数优化。这种架构改进有效缓解了多任务学习中的梯度冲突问题，为工业检测场景中高精度需求提供了新的解决方案。




图 3.6 Coupled Head 模块结构




图 3.7 Decoupled Head 模块结构

3.2.2 损失函数

损失函数是构成目标检测算法的关键组成部分，在算法的学习与优化过程中发挥着至关重要的作用。其主要目的是对预测模型预测结果与实际标注的差异进行量化处理，通过模型指导，实现真实数据分布的精准适配，成功实现了预测精度的巅峰状态。本质上作为深度学习目标检测算法的一部分，损失函数是一种普遍采用的性能衡量工具，本文本力求计算网络预测目标框与实际标注目标框的偏差。具体剖析 YOLOv8 算法，本分类损失函数的核心采用 VFL(Varifocal Loss)，而回归损失函数则结合了 CIOU Loss(Complete Intersection over Union Loss) 与 DFL(Distribution Focal Loss)。

(1) CIOU Loss 函数

在目标检测领域，交并比 (Intersection over Union, IoU) 是评估检测器性能的关键指标。IoU 定义为预测边界框与真实边界框交集面积与并集面积之比，其值越高，表明预测框与真实框的重叠程度越高，检测性能越好。考虑到 IoU 对目标尺度变化的敏感性不足，尤其是在小目标检测任务中表现欠佳，研究者提出了改进的 CIOU (Complete IoU) 损失函数。CIOU 损失函数示意图如图 3.8 所示。设 $l = \rho^2(b, b^{gt})$ 为真实框与预测框中心点间的欧氏距离， c 指的是真实值与预测框形成的最小封闭区域的对角线长度，计算公式如 (3.1)、(3.2)、(3.3) 所

示。

$$CIoULoss = 1 - CIoU = 1 - \left(IoU - \frac{\rho^2(b, b^{gt})}{c^2} - \alpha v \right) \quad (3.1)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2 \quad (3.2)$$

$$\alpha = \frac{v}{(1 - IoU) + v} \quad (3.3)$$




图 3.8 SPPF 快速空间金字塔池化层结构

本公式中的 w^{gt} 和 h^{gt} 分别代表真实边界框的宽度以及高度， w/h 即预测框的宽与高，在公式里， w^{gt}/h^{gt} 和 w/h 分别对应真实与预测目标框的长宽比例数值。该公式中的 v 变量，正是惩罚因子。当宽高比例相等之际， v 变量为零随着宽高比差异的逐步扩大， v 的数值也随着变大。其中的 α 是 v 权重值。

(2) Varifocal Loss 函数

为解决正负样本不平衡问题，采用 Varifocal Loss 函数^[56]所提出的非对称加权操作。Varifocal Loss 函数的公式如下 (3.4) 所示：

$$VFL(p, q) = \begin{cases} -q(q \log(p) + (1 - q) \log(1 - q)) \\ -\alpha P^\gamma \log(1 - p) \end{cases} \quad (3.4)$$

在 Varifocal Loss 的计算中，引入变量 q 来表征样本的性质。对于正样本， q 的取值为预测框与真实框之间的交并比；对于负样本， q 的取值则为 0。因此，当样本为正样本时，Varifocal Loss 退化为标准的二元交叉熵 (Binary Cross-Entropy, BCE) 损失函数；当样本为负样本时，Varifocal Loss 则等价于 Focal Loss。

Varifocal Loss 的设计目标在于训练目标检测模型时，对正负样本进行差异化处理。具体而言，对于正样本，损失函数直接基于预测框与真实框之间的 IoU 值

进行计算；而对于负样本，则采用 Focal Loss 的形式。正样本在损失计算中占据了主导位置，鉴于与负样本的对比，正样本显著增强了模型参数的学习效率。采用此途径 Varifocal Loss 在平衡正负样本贡献方面表现出显著效果，全力优化目标检测模型的整体性能表现。

(3) Distribution Focal Loss 函数

针对图像目标检测这一任务，普遍存在的遮挡与重叠现象，涉及目标间。在这种情形里，传统边界框标注与检测技术难以精确地呈现图像的细致内容。对此研究领域，需要找到有效的解决途径，精细化的边界框表征方法引入是极其必要的。即改用一种更为普遍适用的概率分布模型，用更广泛的函数替换狄拉克 δ 函数。以公式 (3.5) 为基础，网络预测结果 $\hat{y}$ 不再仅仅局限于通过调整通道数来设定坐标值，输出结果属于概率分布范畴，基于此分布对各个坐标分量实施加权，以获取预测坐标的最终结果。该方法在应对目标重叠问题上具有更高的有效性，增强目标检测的精确水平。

$$\hat{y} = \int_{-\infty}^{+\infty} P(x)x dx = \int_{y_0}^{y_n} P(x)x dx \quad (3.5)$$

我们知道检测模型网络输出的固有离散性，连续概率分布无法直接表征，于是采用离散概率点集进行近似表述，具体见公式 (3.6)：

$$\hat{y} = \sum_{i=0}^n P(y_i)y_i \quad (3.6)$$

然而若直接运用此方法进行训练，将导致概率表征空间的维度显著增加，网络优化与收敛可能受挫。在真实坐标的邻近区域，概率性明显较高，由此产生了分布焦点损失 (DFL) 这一理论学说^[57]，其定义如公式 (3.7)：

$$DFL(S_i, S_{i+1}) = -((y_{i+1} - y) \log(S_i) + (y - y_i) \log(S_{i+1})) \quad (3.7)$$

其中 S 即网络概率输出。公式说明若预测值与真实值严密对应，若网络输出概率 S 较大，DFL 的数值偏低从而概率分布向真实标签倾斜。由此可知 DFL 有助于网络迅速将注意力集中在目标值的周边区域，增强这些区域的预测概率能力，加速训练进程，快速进入收敛阶段。

3.3 基于 YOLOv8 的 PCB 微小组件检测算法

3.3.1 DFBA-YOLOv8 模型

与一般的专门为 PCB 组件设计的检测器不同，本文将通用的目标检测框架 YOLOv8 直接运用在 PCB 组件检测上，提出了一种基于 YOLOv8n 改进的 PCB

组件检测算法，结合了可变形卷积（DCNv4）、关注感受野卷积（RFAConv）、基于 BiFPN 改进的 BFPN 多尺度特征融合结构和注意力机制检测头（AMD_Detect）命名为 DFBA-YOLOv8。

为解决小尺度特征提取的挑战与提高网络提取关键特征的能力，本研究在主干网络与颈部间引入了可变形卷积模块 DCNv4，进而提升目标检测的准确度；此外，针对复杂的目标和场景，提出一种关注感受野的卷积模块 RFAConv，替换了原网络颈部下采样操作的 C2f 结构。该模块能够提升模型定位的精度，改善网络的整体性能和效率；针对小目标场景下的检测精度问题，本研究在颈部结构中提出了一种基于 BiFPN 改进的 BFPN 的多尺度特征融合结构，并且针对 PCB 微小组件检测任务舍弃了较大目标检测头，增加了较小目标检测头；提出检测头 AMD_Detect Head 替换原检测头，本技术采用将注意力函数分解为三个独立的序列注意力机制，聚焦于不同的维度，此方法显著降低了计算复杂性，处理速度显著上升。

改进的网络结构图如图 3.9 所示，红色连接线表示新增路径，红色实线模块表示替换或新增的模块。




图 3.9 DFBA-YOLOv8 网络结构

3.3.2 引入可变形卷积 DCNv4 结构

在小目标检测的研究中，传统卷积网络使用的固定网格结构，面对尺寸多变的小物体时，容易漏掉关键特征信息，导致检测结果不够准。尤其是低分辨率图片中的小目标，本身特征就不明显，加上传统网络中的卷积操作需要大量计算资源，实际应用时效率也受到限制。

为解决上述问题，研究者提出了可变形卷积网络（Deformable Convolutional Networks, DCN）^[58]的创新方案。该技术通过动态偏移参数调整采样点分布，使卷积核能根据图像内容自适应改变感受野范围。具体来说，DCN 为每个采样点增加可学习的坐标偏移量，允许卷积核像“橡皮筋”一样贴合目标轮廓。例如检测电路板上的微型电容时，卷积核会自动聚焦到元件边缘区域，显著提升细小目标的特征提取能力。与固定网格的传统卷积不同，DCN 通过训练让网络自主决定最佳采样位置。这种柔性调节机制尤其适用于密集小目标场景——当处理焊点阵列时，卷积核能精确区分相邻元件的边界特征，避免传统方法因固定采样导致的特征混淆问题。

DCNv1 的核心思想主要围绕调整标准卷积的采样点，依据预测偏移量进行。这一过程可以用如下公式（3.8）所示：

$$y(p) = \sum_{k=1}^{w-1} w_k \cdot x(p + p_k + \Delta p_k) \quad (3.8)$$

在式（3.8）中，考虑一个具有 k 个采样点的卷积核。对于每个采样点 k 定义 w_k 为其对应的权重系数， p_k 定义为预定义偏移量。 $x(p), y(p)$ 分别表示输入和输出位置 p 的特征， Δp_k 表示第 k 个采样点所学习到的位置偏移量。

为了提升对非规则几何形态目标的建模能力，DCNv2^[59]在 DCNv1 的基础上进行了改进：DCNv2 为每个采样点引入了独立的权重系数，输出特征值 $y(p_0)$ 可通过如下公式（3.9）计算得出：

$$y(p_0) = \sum_{k=1}^{w-1} w_k \cdot x(p + p_k + \Delta p_k) \cdot \Delta m_k \quad (3.9)$$

公式（3.9）中的 Δm_k 表示第 k 个采样点的调制因子。

考虑一个维度为 $H \times W \times C$ 的输入张量，其中 H 表示高度， W 表示宽度， C 表示通道数。对于该输入张量中的每个位置 p_0 ，DCNv3^[60]操作通过聚合 K 个采样点的信息来计算输出特征。该聚合过程可由以下公式（3.10）精确定义：

$$y_g = \sum_K^{g_k} m_{gk} (p_0 + p_k + Dp_{gk}) \quad (3.10)$$

尽管如此早期版本的可变形卷积网络在应用领域，计算速度与效率难题依旧构成瓶颈。应对这些局限性，近日最近，新一代的可变形卷积神经网络 DCNv4^[61]被研发。DCNv4 的核心机制经过优化，创新性显著提升，网络的动态性和表达能力大幅增强。下图 3.10 展示了 DCNv3 与 DCNv4 的结构对比。




图 3.10 DCNv3 和 DCNv4 结构对比

图 3.10 展示了 DCNv3 与 DCNv4 的架构演进。DCNv4 的核心改进包括三方面：取消特征聚合时的概率归一化步骤，将原本受限的调制权重扩展为无约束的动态参数；重构内存访问机制，实现通道组内参数共享；优化插值计算流程以提升效率。相较于 v3 版本，v4 的动态权重机制不再限制参数范围，允许网络根据输入特征自主调整采样点贡献度。例如在处理微小元件时，网络可自动增强关键区域（如元件边缘或焊点中心）的响应强度，而无需受限于归一化后的权重分布。这一调整使得特征筛选过程更贴合目标的实际形态分布。在计算优化方面，v4 通过通道组内共享采样偏移与权重参数，显著减少内存访问频次。同时采用合并式插值计算策略，降低冗余操作对硬件资源的消耗。优化后的数据流设计使前向传播阶段的内存读写效率大幅提升，尤其在高分辨率图像处理场景下，模型响应速度与实时性表现更为突出。

YOLOv8 模型的 C2f 模块采用多级瓶颈结构（Bottleneck）进行特征提取，这一设计可以捕获多种尺度的特征信息，增进模型的表现力。由于标准卷积操作的感受野有限，瓶颈结构在处理小目标图像的几何形变时，其功能表现受到一定程度的制约。本研究针对 YOLOv8 骨干部分的 C2f 模块进行了重构，并引入了 DCNv4 的可变形卷积模块，以此优化模型对小目标图像几何形变的捕捉效果。如图 3.11 所示，整合了 C2f-DCNv4 模块。




图 3.11 C2f-DCNv4 模块结构

在 YOLOv8 模型的骨干中集成 C2f-DCNv4 模块，能够在保持模型预测精度的前提下，显著提高计算效率和资源利用率。DCNv4 的引入增强了模型的自适应性和动态感受野，从而使其能够更有效地应对小目标检测等复杂视觉任务。

3.3.3 RFACnv 关注感受野的卷积模块

注意力机制已成为提升网络模型性能的有效策略。其核心思想在于对输入数据施加权重，引导模型聚焦于关键特征，同时抑制非重要信息，进而提升整体性能。注意力机制主要可划分为以下三类：（1）通道注意力机制；（2）空间注意力机制；（3）混合域注意力机制。

现有的空间注意力机制，如 CBAM（卷积块注意力模块）^[62]和 CA（坐标注意力）^[63]，主要集中于空间特征的提取，但尚未成功突破卷积核参数共享的障碍。为填补这一空白，有研究提出了一种名为感受野注意力机制（Receptive-Field Attention, RFA）的注意算法^[64]。与现有技术相较，RFA 不仅聚焦于感受野的空间特性，也能对大尺寸卷积核实施有效关注赋予。本研究依托 RFA 原理，设计了一种新的卷积运算方式，即 RFACnv。RFACnv 将射频识别与卷积运算有效结合，在计算成本及参数量几乎维持原状之时，网络性能明显上升。由此可见 RFACnv 是现有神经网络中标准卷积运算的理想替代选项。本研究旨在验证 RFACnv 技术的有效性，故将其集成到 YOLOv8 的 Neck 结构中，用 RFACnv

卷积模块替换了 C2f 的下采样环节。实验结果揭示，这一措施能够提高模型的检测精确度，进一步加强网络的整体性能与效率。

感受野的空间特性是专为卷积核设计的，其生成呈现出动态性，且与卷积核的宽度紧密绑定。图 3.12 以 3×3 卷积核为例，揭示了空间特征与原始特征图的对应关系，以及感受野空间特征（Receptive-Field Feature）作为对原始特征图实施特定转换后所形成的特征映射。此变换将原始特征图分割成一系列互不重叠的滑动窗口，以形成感受野空间属性。在探讨感受野空间特征时，每个 3×3 的窗口均映射为感受野单元。




图 3.12 感受野空间特征

所提出的方法不仅强调了感受野滑块内各特征的异质性，还突出了感受野的空间特征。该方法从根本上解决了卷积核参数共享所带来的局限性。因此，感受野注意可视为一种固定的卷积组合，其实现依赖于卷积操作的支持；同时，卷积操作的性能提升也有赖于感受野注意力的辅助。基于此，本文提出了一种新型卷积操作：关注感受野的卷积模块（RFACnv）。图 3.13 展示了具有 3×3 卷积核的 RFACnv 模块的整体结构。




图 3.13 RFAConv 模块总体结构

RFAConv 模块通过三级处理流程实现局部特征整合：首先采用全局平均池化提取各感受野的统计特征，随后通过跨通道的 1×1 卷积建立特征间关联性，最终借助 Softmax 函数生成空间注意力权重。该机制使模型能够依据上下文信息动态调整各局部区域的特征贡献度，其数学建模过程详见公式 (3.11) 所示。

$$F = \text{Softmax}(g^{1 \times 1} \text{AvgPool}(X)) \times \text{ReLU}(\text{Norm}(g^{k \times k} X)) = A_{rf} \times F_{rf} \quad (3.11)$$

其中 $g^{i \times i}$ 为分组卷积, k 表示的是卷积核的尺寸大小, Norm 表示归一化操作, X 为输入的特征图, 感受野注意力特征 F , 可通过将注意力图谱 A_{rf} 与经过变换的感受野空间特征 F_{rf} 进行逐元素乘法运算获得。此过程有别于 CBAM 和 CA 模块, RFA 模块的独特之处在于能够为每个感受野特征独立生成对应的注意力图谱。标准卷积操作由于采用共享参数, 对空间位置变化所引入的差异信息捕获能力有限, 这在一定程度上制约了 CNN 的性能。RFA 模块则通过其特有的机制, 有效地规避了这一问题。RFA 模块的计算过程可由公式 (3.12) 详细阐述。

$$\begin{aligned} F_1 &= X_{11} \times A_{11} \times K_1 + X_{12} \times A_{12} \times K_2 + \dots + X_{1S} \times A_{1S} \times K_S \\ F_2 &= X_{21} \times A_{21} \times K_1 + X_{22} \times A_{22} \times K_2 + \dots + X_{2S} \times A_{2S} \times K_S \\ F_N &= X_{N1} \times A_{N1} \times K_1 + X_{N2} \times A_{N2} \times K_2 + \dots + X_{NS} \times A_{NS} \times K_S \end{aligned} \quad (3.12)$$

鉴于区域特征聚合生成的特征图源自经过维度重塑的、互不重叠的感受野空间特征, 故可通过池化操作整合每个感受野单元的特征信息, 进而构建可学习的注意力图。此方法有效规避了现有通道注意力 (CA) 及卷积块注意力模块 (CBAM) 在大尺寸卷积核注意力机制中存在的参数共享局限性。经过维度重塑, 特征图的

高度和宽度均扩展为原尺寸的 k 倍,为有效提取特征信息,需采用步长为 k 的 $k \times k$ 卷积运算。因此由 RFA 特别设计的卷积运算模块 RFACnv 即为 $k \times k$ 卷积操作。

3.3.4 基于 BiFPN 的多尺度特征融合

随着网络层级逐步扩展,模型表征能力的提升伴随特征抽象程度的深化。在深层特征抽象化过程中,微小目标细节的梯度消失现象逐渐显现,导致局部敏感信息衰减。为平衡特征语义强度与空间分辨率,跨层级特征交互机制成为关键解决方案。浅层特征虽富含高频细节,但直接引入会引发计算复杂度的指数级增长,同时干扰高层语义的判别性。针对该问题,学界已形成特征金字塔(FPN)、路径聚合(PANet)及双向特征融合(BiFPN)等典型范式。如图 3.14 所示,FPN 采用自上而下的单向传播路径实现语义增强,PANet 补充自底向上的二次融合,而 BiFPN 通过双向跨尺度连接建立自适应加权机制。这些架构通过差异化的信息流设计,在计算效率与特征保真度之间实现动态平衡。




图 3.14 不同的多尺度特征融合结构

上图 3.14 (a) 展示了特征金字塔网络(FPN)的层级融合机制。该架构通过自上而下的层级连接结构,将深层网络的高层语义特征与浅层网络的底层细节特征进行跨尺度融合,显著提升多尺度目标的识别效果。然而,其层级交互过程存在两方面的局限性:深层特征经多级上采样操作后,局部几何细节(如微小元件的边缘轮廓)易出现渐进式丢失,导致空间定位偏差;不同抽象层级的特征图(如高层类别语义与底层纹理细节)直接融合时,可能因层级间语义鸿沟削弱融合表征的判别性。

通过融合 FPN 的自顶向下传播路径与 PAN 的自底向上反馈路径,构建多级特征交互机制,YOLOv8 采用双向跨层级连接架构,即 PANet 结构,如图 3.14 (b) 所示。该设计旨在增强低层级几何细节(如元件轮廓)与高层级语义上下

文（如器件类别）的协同表征能力。然而该架构在实现跨层级特征交互时，未充分融合上层卷积层的细粒度特征（如焊点纹理），可能导致微小型目标的边缘响应弱化，这可能会对小目标检测的精度产生影响。

BiFPN (Bidirectional Feature Pyramid Network) 结构作为 Google 公司在 2020 年发表的《EfficientDet》论文^[65]中提出的一种特征融合模块，具体内容详见图 3.14 (c)。基于 PANet 的多尺度特征融合理念，该结构采用了加权双向特征金字塔网络。采用可学习权重技术，BiFPN 可自动调整各类输入特征的权重。该结构不仅迭代采用了自顶向下和自底向上的多尺度特征融合策略，还整合了双向跨尺度连接与快速归一化融合的特性，使多尺度特征融合变得既高效又便捷。

为解决小目标检测中浅层特征信息难以提取的问题，本研究借鉴了双向特征金字塔网络 BiFPN 的设计理念，对特征金字塔网络和路径聚合网络的融合结构进行了简化。具体而言，在 YOLOv8n 网络模型的基础上，本研究摒弃了原有的特征加权机制，转而采用一种更为直接的多层级特征融合策略，删除了分辨率最小、语义最丰富的一层输出层，新增了分辨率更大的一层、小组件特征保留最全面的输出层。该策略将主干网络不同层级的计算结果，以单次或多次的途径，引入特征增强提取网络。图 3.15 展示了基于 YOLOv8n 模型改进的、去除权重机制的 BiFPN 结构。




图 3.15 基于 BiFPN 的 YOLOv8 Neck 结构

基于 BiFPN 的 YOLOv8n 采用了一种新颖的跨尺度特征融合方法，具体实现方式为在网络的 P3 和 P4 层之间构建双向跳跃连接。该设计显著促进了特征传播的效率增长，进而采用了无权重的特征结合机制，与此同时简化计算复杂性，维护了特征的完整性及多样性。此外通过双向跨尺度连接，BiFPN 促进了信息在各层级间的自由传递，进而实现了高层语义与底层细节信息的有效整合。

3.3.5 基于注意力机制的动态检测头

针对小规模目标检测的应用场合，检测算法必须拥有强大的全局感知特性，应对复杂环境、众多密集小目标、目标相互遮挡及模糊细节等多重挑战。尽管 YOLOv8 算法运用了解耦头（Decoupled Head）的体系，将分类与检测的任务各自分开，进而加强了模型对任务的聚焦度，尽管有所成就，但仍存在局限：（1）采用传统单一尺度的预测机制：本算法处理多尺度对象，特别是在识别小型物体上存在识别能力不足的问题。（2）预测头上下文信息利用不充分：预测过程缺乏全局视野，各预测独立进行，未能充分整合上下文信息。（3）预测头参数量有限定：有限的参数量对预测头的表现能力构成制约，这种影响降低了其挖掘特征空间结构信息的能力水平。

鉴于当前所面临的挑战，本项研究开发了一种基于注意力原理的动态检测头 AMD_Detect Head（Attention Mechanism Dynamic Detection Head）。通过将注意力函数拆分为三个序列，AMD_Detect Head 实现了对注意力机制的优化，各自聚焦于不同的角度。尤其是在针对小目标的检测等复杂情境中，该设计让 AMD_Detect Head 能够更精确地捕捉目标在尺度、空间位置及任务相关信息方面的变动，因而检测表现大幅提高。如图 3.16 所描绘采用序列化排列方式，动态检测头结合了三种注意力机制。




图 3.16 AMD_Detect Head 检测头结构

如上图所示，各序列注意力单元均聚焦于单一模块，由此构建了一种嵌套式注意力函数结构。该结构可由公式（3.13）精确表述：

$$W(\mathcal{F}) = \pi_c(\pi_s(\pi_L(\mathcal{F}) \cdot \mathcal{F}) \cdot \mathcal{F}) \cdot \mathcal{F} \quad (3.13)$$

上述公式中 W 代表注意力函数，在特征金字塔网络中，第 i_{th} 层特征图可以表示为一个 3 维的张量 $F_i \in \mathbb{R}^{L \times S \times C}$ ， $\mathcal{F}$ 为给定的特征张量 $\mathcal{F} \in \mathbb{R}^{L \times S \times C}$ 。其中 L 代表特征图的层级， S 代表特征图的空间维度即宽高乘积， C 代表特征图的通道数。 $\pi_c(\cdot)$ 、 $\pi_s(\cdot)$ 、 $\pi_L(\cdot)$ 分别表示任务感知注意力模块、空间感知注意力模块以及尺度感知注意力模块，每个注意力模块分别在 C 、 S 和 L 三个维度上执行。

为显著提升模型对目标，特别是小目标的表征能力，并增强检测的灵活性与精确性，本研究引入了一种多维度注意力机制。该机制综合考虑了尺度感知特征层级间的注意力、空间感知空间位置间的注意力以及任务感知输出通道间的注意力。下文将详细阐述各模块的工作原理。

(1) 任务感知注意力模块：该模块动态调整特征通道的激活状态，进而满足各类任务需求。其计算流程数学建模如公式 (3.14)：

$$\pi_c(\mathcal{F}) \cdot \mathcal{F} = \max(\alpha^1(\mathcal{F}) \cdot \mathcal{F}_c + \beta^1(\mathcal{F}), \alpha^2(\mathcal{F}) \cdot \mathcal{F}_c + \beta^2(\mathcal{F})) \quad (3.14)$$

在公式 (3.14) 中， $\pi_c(\cdot)$ 表示任务定制的注意力机制，其中 $\mathcal{F}_c$ 为第 C 个通道的特征映射。超参数 $[\alpha^1, \alpha^2, \beta^1, \beta^2]^T = \theta(\cdot)$ 定义了一组用于调节激活阈值的可学习参数。 $\theta(\cdot)$ 首先对尺寸为 $L \times S$ 的特征图执行全局平均池化操作，以降低特征维度。随后依次经过两个全连接层和一层归一化处理，最后通过一个带有偏移量的 Sigmoid 激活函数将输出映射至 $[-1, 1]$ 区间。其中， α 和 β 均为可学习参数，通过这些参数对不同通道进行差异化激活，从而实现注意力机制。

(2) 空间感知注意力模块：引入空间感知注意力模块以聚焦于空间位置与特征维度上同时存在的差异性区域。其数学表达式如公式 (3.15) 所示：

$$\pi_s(\mathcal{F}) \cdot \mathcal{F} = \frac{1}{L} \sum_{l=1}^L \sum_{k=1}^K w_{l,k} \cdot \mathcal{F}(l; p_k + \Delta p_k; c) \cdot \Delta m_k \quad (3.15)$$

在公式 (3.15) 中， $\pi_s(\cdot)$ 代表空间感知注意力模块。其中， K 表示稀疏采样点的总数， $p_k + \Delta p_k$ 表示一个可调整的采样点位置。该位置可根据自适应学习到的空间偏移量 Δp_k 进行动态调整，以实现关键区域的精确识别与聚焦。 Δm_k 表示位于位置 p_k 处的一个自学习的重要性标量。空间偏移量 Δp_k 和 Δm_k 这两个参数均可通过网络中间特征层 F 中的输入特征进行自动学习和调整。

(3) 尺度感知注意力模块：该机制依据语义显著性对多尺度特征进行动态融合，具体而言就是尺度感知注意力模块根据上下文的语义相关性执行多尺度特征融合，其计算过程 $\pi_L(\mathcal{F})$ 如式 (3.16) 所示。

$$\pi_L(\mathcal{F}) \cdot \mathcal{F} = \sigma \left(f \left(\frac{1}{SC} \sum_{S,C} \mathcal{F} \right) \right) \cdot \mathcal{F} \quad (3.16)$$

上式中 $\mathcal{F}(\cdot)$ 利用 1×1 卷积近似的线性函数达到降维特征的作用。 $\sigma(x) = \max(0, \min(1, (x + 1)/2))$ 为 Hard-Sigmoid 激活函数，尺度感知注意力模块的应用，增强了特征对多尺度目标的辨识能力。

依次在网络中实现了上述三种注意力机制，并且支持叠加实施，称为 AMD_Detect Head 检测头。鉴于硬件资源的局限性以及轻量化设计的需求，本研究使用了串联方式设计的 AMD_Detect Head 模块。

3.4 实验结果及分析

3.4.1 SPCB-Datasets 数据集

考虑到 PCB 组件检测领域已有数据集较少，为了解决数据集建立的问题，我们使用了公共数据集 pcb_wacv_2019^[66]中的 47 个物理 PCB 组装图像这些 PCB 照片有些来自互联网，有些来自工业相机拍摄而成。同时我们还加入了 FICS^[67]中提出的名为 FICS 的公开数据集，两种数据集经处理混合在一起形成本文的数据集，命名为 SPCB-Datasets。

在 pcb_wacv_2019 数据集中，组件标签名称由设备名称+丝印编号组成，如 'capacitor C18'、'resistor R2'，可见这个数据中的标签非常庞大和详细，但同时也非常冗余。对于元器件识别的任务，本研究去掉了电子元器件的丝印编号，将同类型的元器件分组在一起，即 capacitor、resistor 分别为两个类别。所有印在电路板上的丝印编号都被标为一类，即文字类别（text）；组件上面的丝印内容标签为组件文字类（component text）。在使用 pcb_wacv_2019 数据集之前，我们对数据集的标签数据进行了统计分析。我们发现，总共有 18108 个对象，这意味着每个图像平均包含 385 个组件。更重要的是，有时微小的电阻器、电容等 50% 的元件都集中在一个很小的区域，只占整个图像的 10%。总而言之就是元器件密集地出现在电路板上或电路板的局部小区域上。

对于我们收集到的 FICS 公开数据集，该数据集包含来自三个方面的具有挑战性的案例：光照、图像尺度和图像传感器。在这个数据集中，使用数字单反相机（DSLR）设备拍摄了 51 张完整的 PCB 板图像，并对这些图像进行了标注。还有用显微影像拍摄（microscope）的图片，将 PCB 板按照固定尺寸进行扫描，从上至下，左至右移动拍摄，图像大小固定在 1600×1200 像素（width*height）。其中的变量是光照强度和显微镜的放大倍数，光照强度分为 20、40、60，其中 20 参数最亮；放大倍数分为 1x、1.5x、2x，其中 1x 的视野最大，信息最全面，组件相对地就会越小。如下图 3.17 所示，前两者是同一块区域光照强度不同的差异，最后一张图片和前两张图片的不同则在于显微镜的放大倍数上，能看到 1x 的倍数视野更加的广阔。




图 3.17 FICS 数据集示例

基于 FICS 的裁剪以及控制光照强度不同的思想, 对 pcb_wacv_2019 数据集进行相应的处理, 实现随机裁剪, 获得尺寸为 640×640 像素的子图像。为了避免过度拟合问题, 必须应用数据增强技术来产生丰富的实例。在这项工作中, 我们使用了传统的几何变换和形态学操作, 包括旋转、翻转、转置和随机亮度对比度在内的色彩空间转换。处理后的数据集示例如图 3.18 所示。




图 3.18 pcb_wacv_2019 处理后数据集示例

最后, 我们将两个处理后的数据集合并, 增加了数据样本的多样性, 将该数据集命名为 SPCB-Datasets。本文制作的 SPCB-Datasets 数据集共有 14602 张图片, 其中有由 pcb_wacv_2019 裁剪并经过数据增强后生成的 11330 张, 加上 FICS 数据集中原有的 3272 张带有标签的图片而成。我们将数据集按 7:1.5:1.5 的比例划分为训练集、验证集和测试集, 其中训练集 10222 张、验证集 2190 张、测试集 2190 张。用于训练的标签的分布和维度如下图 3.19 所示。




图 3.19 SPCB-Datasets 训练标签分布和尺寸

上图中 (a) 表示目标中心点相对于整个图的位置, 表明目标在整个图像中是均匀分布的, 而不是聚集在特定区域, 这是因为我们将 PCB 图片剪裁后, 图片大小均为 640×640 像素, 其中的组件分布相比于整张 PCB 图像而言更为均匀。x 轴表示标签中心坐标与图像宽度的比值, y 轴表示标签中心坐标与图像高度的比值。这些比率提供了一个用于定位图像内标签的标准化度量。图中 (b) 显示了标签尺寸与图像尺寸的比率, 表明 PCB 组件在尺寸上非常多样化, 整个数据集的检测尺度偏小。下表 3.1 给出 SPCB-Datasets 中每个目标类别的数量, 可以看出组件类别数量分布不平均, 这是因为由于组件功能不同决定的, 像电阻、电容器这一类常常会用到的组件, 在一块 PCB 上出现的个数就会越多。

表 3.1 训练集中每个类别标签数量

组件种类	训练集	验证集	测试集	总数
电阻 (resistor)	35761	7775	7689	51225
电容 (capacitor)	41295	8976	9056	59327
集成芯片 (IC)	5079	1104	1023	7206
二极管 (diode)	1108	241	235	1584
电感器 (inductor)	1039	253	230	1522
晶体管 (transistor)	1350	273	281	1904
连接器 (connector)	4985	748	731	6464
文本 (text)	9496	2064	2187	13747
组件文本(component text)	92228	20049	21543	133820

3.4.2 实验环境及实验参数设置

本章算法所有的实验都是在 PC 端 Ubuntu20.04 系统下完成的,硬件配置 CPU 为 Intel i9-10900KF, GPU 为 NVIDIA RTX3090, 显存容量为 24GB。软件配置采用 Python3.8 编程语言以及 Pytorch1.11.0 深度学习框架, 使用 CUDA11.3 和 Cudnn8.2.2 对 GPU 加速。具体的实验环境如表 3.2 所示。

表 3.2 实验环境

实验环境配置	
操作系统	Ubuntu20.04 64bit
语言	Python3.8
框架	Pytorch1.11.0
CUDA	11.3
Cudnn	8.2.2
GPU	NVIDIA RTX3090
CPU	Intel i9-10900KF

为保障实验的公平性、可对比性,我们对网络模型训练中的参数进行统一设置,如下表 3.3 所示具体说明了实验中网络训练时主要的参数说明及解释。

表 3.3 网络训练参数设置

实验环境配置		
参数	参数设置值	参数解释
Pre-trained weight	No	不使用预训练权重
Image_size	640×640	输入网络图片尺寸
Batch_size	16	每个训练批次图像数量
Epoch	300	网络训练总轮次
Optimizer	SGD	优化器
lr0	0.01	初始学习率

续表 3.3 网络训练参数设置

实验环境配置		
Momentum	0.937	学习动量
Weight_decay	0.0005	权重衰减
box	0.05	目标框损失权重
obj	0.7	置信度权重损失
cls	0.3	分类损失权重
Mosaic	1.0	选取四张不同的图片进行随机裁剪、缩放、分布的拼接组合操作的概率，取值范围为 0 到 1 之间
Close_mosaic	10	在最后 10 个周期中禁用 mosaic 数据增强，以在训练结束前稳定训练。

3.4.3 消融实验

为评估本文所提出改进措施的有效性，以 YOLOv8n 模型为基准模型，设计并实施了一系列消融实验。实验结果详见表 3.4 所示。

表 3.4 消融实验对比结果

YOLOv8n	DCNv4	RFACnv	BPFPPN	AMD_Detect Head	P (%)	R (%)	mAP@0.5 (%)	mAP@0.5:0.95 (%)
√					81.2	76.3	83.4	57.2
√	√				81.9	77.2	83.9	58.1
√		√			82.2	77.5	84.6	58.3
√			√		83.4	78.3	85.5	58.9
√				√	83.2	77.9	85.2	58.2
√	√		√		83.8	78.8	85.9	59.1

续表 3.4 消融实验对比结果

YOLOv8n	DCNv4	RFACnv	BPFPN	AMD_Detect Head	P (%)	R (%)	mAP@0.5 (%)	mAP@0.5:0.95 (%)
√		√	√		84.1	78.9	86.2	59.4
√			√	√	84.9	79.5	87.3	60.5
√	√		√	√	85.2	80.2	87.6	60.9
√		√	√	√	85.4	80.7	87.8	61.2
√	√	√		√	84.9	81.1	86.5	60.6
√	√	√	√	√	86.3	81.9	88.6	61.6

从上表中的消融实验我们可以看出在 YOLOv8n 的基础上分别在骨干网络中引入 DCNv4 模块, 在 Neck 中用 RFACnv 替换 C2f 完成下采样操作, 在 Neck 中引入 BPFPN 结构, 替换检测头为 AMD_Detect Head 后, 精确度、召回率和模型的检测精度均有所提升。通过消融实验发现单独引入 BPFPN 结构带来的提升比单独引入其他模块高, 与 YOLOv8n 相比, 提高了 2.1% 的 mAP@0.5、1.7% 的 mAP@0.5:0.95, 这可能是因为 BPFPN 结构可以让网络学习到更多小目标的特征, 其中新增的小目标检测头可能也为精度带来了提升; 在此基础上再加入 AMD_Detect Head 模块, 与 YOLOv8n 相比, mAP@0.5 提升了 3.9%、mAP@0.5:0.95 提升了 3.3%, 这可能是因为 AMD_Detect Head 能够更精确地捕获目标在尺度、空间位置和任务相关信息方面的变化, 从而显著增强检测性能。继续使用 RFACnv 模块后, 与 YOLOv8n 相比, mAP@0.5 提升了 4.4%、mAP@0.5:0.95 提升了 4.0%。最后引入 DCNv4 后, 与 YOLOv8n 相比, 本文的模型准确率提升 5.1%、召回率提升 5.6%、mAP@0.5 提升了 5.2%, mAP@0.5 达到 88.6%, mAP@0.5:0.95 提升了 4.4%。实验证明我们提出的检测模型对于 PCB 组件检测任务是有效的。

3.4.4 对比实验及效果展示图

为验证本章提出模型的性能, 对比了双阶段目标检测模型 Fast-RCNN 和 Faster-RCNN; 单阶段的模型有 YOLOv3-tiny、YOLOv4-tiny、YOLOv5-small、YOLOv7-tiny、YOLOv8n、YOLOv10-N 和小目标检测器 YOLO-Z; 其他研究者提出的 PCB 组件检测模型如 DInPNet^[38]和 YOLOv8-PCB^[40]等。在相同的数据集、

实验环境下进行训练和测试，各模型的参数配置均使用默认值。对比实验如下表 3.5 所示，对比了 15 种检测模型与本文模型的性能表现。

表 3.5 对比实验结果表

模型	参数量 (M)	mAP@0.5	mAP@0.5:0.95	FPS
Fast-RCNN	58.7	61.2%	47.3%	9
Faster-RCNN	41.14	64.9%	49.7%	13
YOLOv3-tiny ^[49]	12.16	81.2%	56.8%	83
YOLOv4-tiny ^[50]	6.65	62.9%	45.4%	147
YOLOv5-small ^[51]	7.19	78.6%	56.1%	105
YOLOv7-tiny ^[53]	6.02	52.7%	38.1%	131
YOLOv8n ^[54]	3.20	83.4%	57.2%	113
YOLOv10-N ^[55]	2.89	81.5%	55.8%	125
YOLO-Z ^[39]	4.13	79.3%	53.9%	118
YOLOv3-PCB ^[33]	13.28	69.1%	51.7%	91
PeleeRCNN ^[34]	37.85	66.4%	50.3%	11
YOLOv4-PCB ^[37]	6.95	62.5%	48.2%	106
DInpNet ^[38]	5.36	71.3%	48.9%	75
YOLOv8-PCB ^[40]	4.27	82.1%	56.8%	98
DFBA-YOLOv8	3.43	88.6%	61.6%	103

由上表分析模型检测结果对比可知，如 Fast-RCNN 和 Faster-RCNN 这种双阶段目标检测算法的模型参数量偏大，检测精度和速度都较低，较好的 Faster-RCNN 模型的检测精度 mAP@0.5 和 mAP@0.5:0.95 分别为 64.9% 和 49.7%，FPS 只有 13。而单阶段目标检测算法 YOLOv3-tiny、YOLOv4-tiny、YOLOv5-small、YOLOv7-tiny、YOLOv8n、YOLOv10-N 和 YOLO-Z 它们在检测精度、速度上有所提升，模型参数量也减少许多。YOLOv4-tiny 和 YOLOv7-tiny 模型在检测速度上领先，但是精度较低。YOLOv10-N 的参数量较 YOLOv8n 减少了 0.18M，检测速度提高 12FPS，但是检测精度有所下滑，降低了 1.9% 的 mAP@0.5，可能是因为 YOLOv8n 可能在设计中保留了更多细节特征提取层（如 C2f 模块、更复杂的检测头），其中未改进的算法里性能最好的是 YOLOv8n，mAP@0.5 和 mAP@0.5:0.95 可以达到 83.4% 和 57.2%。而同类的 PCB 组件检测算法，在我们的 SPCB-Datasets 数据集上，其检测效果不佳，可能是因为数据集与原作者实验

所用有差距导致。在同样的实验环境下，我们的模型达到了 88.6%的 $mAP@0.5$ 和 61.6%的 $mAP@0.5:0.95$ 的最高检测精度，在检测速度方面，本文提出的模型与 YOLOv8n 相比，参数量和检测速度的增量微乎其微，我们的模型获得了 103FPS 的检测速度。

本文提出模型与 YOLOv8n 模型检测结果对比如图 3.20 所示，左侧为真实标签，中间是我们提出的网络检测结果，右边的是 YOLOv8n 网络的检测结果。可以看出箭头 1 表示冗余的检测框，箭头 2 表示 YOLOv8n 错误地将背景检测为连接器。因此我们提出的模型 DFBA-YOLOv8 在实时、高精度的 PCB 检测行业中具有较高的潜力，将促进 PCB 的零误差质量控制，显著降低生产成本。




图 3.20 基准标签（左）、DFBA-YOLOv8（中）网络与 YOLOv8n（右）检测对比图

下图 3.21 所示为本文提出模型(a)与同类 PCB 组件检测算法 YOLOv8-PCB^[40] (b) 和 DInPNet^[38] (c) 的模型检测结果对比图。从下图我们可以看出我们提出的 DFBA-YOLOv8 模型检测出的组件最全，像 (b) 中的红色箭头所示的小组件在 (b) (c) 中均漏检，而我们的模型检测出来了，(c) 模型的漏检率较高。




图 3.21 DFBA-YOLOv8 (a)、YOLOv8-PCB^[40] (b) 网络与 DInPNet^[38] (c) 检测对比图

3.5 本章小结

为了提高 PCB 组件的检测精度，保障硬件安全，本章提出了一种基于 YOLOv8n 的无锚框的 PCB 组件检测算法 DFBA-YOLOv8。为解决小尺度特征提取的挑战，在主干网络与颈部间采用可变形卷积 DCNv4 模块旨在增强网络提取关键特征的能力，进而提高目标检测的准确性；此外针对复杂的目标和场景，提出一种关注感受野的卷积模块 RFACnv，替换了原网络颈部下采样操作的 C2f 结构。该模块能够提升模型定位的精度，改善网络的整体性能和效率；其次针对小目标场景下的检测精度问题，本研究在颈部结构中引入了一种 PBFPN 的多尺度特征融合结构，并且针对 PCB 微小组件检测的任务舍弃了较大目标检测头，增加了较小目标检测头；最后本研究提出了一种基于注意力机制的动态检测头 AMD_Detect Head，各自聚焦于不同的角度，精确地捕捉目标在尺度、空间定位及任务相关信息的变动，因而检测效能明显提升。通过消融实验和对比实验进一步证明 DFBA-YOLOv8 网络在 PCB 组件检测任务中的有效性，mAP@0.5 达到 88.6%，mAP@0.5:0.95 达到 61.6%，检测速度达到与 YOLOv8n 几乎一致的 103FPS。本文研究结果将有助于推动 YOLO 模型发展及其在 PCB 组件检测领域的工程应用。

第 4 章 基于轻量化 RT-DETR 的 PCB 组件检测算法研究

在第三章中，我们提出的 DFBA-YOLOv8 模型相较于基准模型 YOLOv8n，在检测精度上实现了 3.2% 的 $mAP@0.5$ 提升，同时维持了 103FPS 的推理速度，初步验证了改进策略的有效性。基于 SPCB-Datasets 的实验数据显示，该模型 88.6% 的检测精度虽已达到工业部署的基本要求，但面对 PCB 硬件安全检测中微米级缺陷识别的特殊需求，仍需探索更精细的特征表征方法。为此，本章引入具有全局注意力机制的 RT-DETR 模型，通过融合轻量化、高精度的设计，着力突破小目标检测的性能瓶颈。

4.1 Transformer 模型概述

Transformer 模型^[68]最初被设计用于自然语言处理领域，旨在处理 RNN 模型内含的并行化难题及内存存储的有限性。自注意力机制构成了该模型的核心，该整体结构是由一系列编码器和解码器模块层层堆叠构成，其结构特点如图 4.1。




图 4.1 Transformer 结构图

由图可知经过输入映射阶段，必须对位置编码实施向量相加运算。此步骤的

必要性在于，Transformer 模型摒弃了 RNN 的序列依赖结构，转而采用全局信息处理机制。然而在自然语言处理任务中，序列的顺序信息具有至关重要的作用。为保留输入序列中的位置信息，引入位置编码是必不可少的。编码器（Encoder）结构整合了多分支自注意力并行架构、跳跃连接、层标准化组件以及位置感知前馈网络等关键组件。其核心的多头处理机制通过并行化多个自注意力子模块，使模型能够协同捕获不同特征子空间的关联模式。如图 4.2 所示的结构分解示意图，具体呈现了单头自注意力单元的内部运算流程。




图 4.2 自注意力机制示意图

在上述图示中，输入矩阵经过不同的线性变换，分别生成查询矩阵（Query Matrix，简称 Q）、键矩阵（Key Matrix，简称 K）和值矩阵（Value Matrix，简称 V）。Q 与 K 矩阵相乘产出后，紧接着调整缩放系数。在解码器的局部自关注机制区域，鉴于预测进程的时序属性，必须实施掩码处理。具体而言在预览特定数据点之际，必须对该数据点之后的所有数值进行遮蔽，为确保预测的准确性，仅用当前及历史数据。然后运用 Softmax 函数对经过缩放及掩码处理的矩阵实施归一化措施。最终对归一化矩阵执行与 V 矩阵的相乘动作，即可实现最终产出。公式 4.1 为 Softmax 函数的公式定义：

$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum_{n=1}^N e^{x_n}} \quad (4.1)$$

在所提出的公式中，N 代表经过归一化处理后的向量长度，而 x_i 则表示该向量中第 i 个元素的值。自注意机制的数学公式如 4.2 所示：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4.2)$$

上式中的 d_k 为 Q 矩阵的列数。

在多头注意力模型里，Q、K、V 向量各自经历独立的线性变换，随后进行

自注意力计算。经过计算我们将各组的自注意力结果在通道维度上拼接，数学公式的具体形式请见式 4.3:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_n)W^O \quad (4.3)$$

上式中 W^O 为可学习的参数矩阵， n 为头的个数， $head_i$ 的表达式如 4.4 所示:

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (4.4)$$

上式中 W_i^Q 、 W_i^K 、 W_i^V 是用于映射 Q 、 K 、 V 的可学习参数矩阵。

残差连接方法的核心是整合高层与低层特征，加强特征提取的分辨能力。采用层归一化方法，对每一层的数据分布进行标准化处理，以此实现各层数据分布的相似性，从而显著提升网络的学习效率。该前馈网络由两个全连接层构成，其中第一层特别采用了 ReLU 激活函数来引入非线性特性。Transformer 编码模块采用堆叠式架构，初始单元处理原始输入序列，后续单元逐级解析前驱单元输出的上下文表征。解码器设计引入三项核心改进：掩蔽式多分支注意力确保时序生成约束，跨模块残差连接维持梯度流稳定性，层级联结构建深度依赖建模能力。在跨模态注意力机制中，键值矩阵源自编码器的最终隐状态表征。

4.2 DETR 模型理论基础

Transformer 架构最初在自然语言处理领域取得突破性进展，随后其注意力机制被拓展至计算机视觉任务。2020 年 Meta 研究团队提出的 DETR (Detection Transformer) 框架，与传统的基于锚框的检测网络相比，DETR 展现出明显的不同，它不依赖预先设定的锚框，且在预测过程中不使用非极大值抑制来筛选掉置信度较低的多余结果。采用 DETR 技术可以直接预测结果集合，显著增强了目标检测流程的执行能力。图 4.3 深入剖析了 DETR 的模型构成。




图 4.3 DETR 模型结构图

如上图所示，DETR 模型的体系结构主要包含以下几个核心组件：卷积神经网络用于提取图像特征，位置编码用于提供序列信息，Transformer 编码器和解码器用于处理序列间的依赖关系，以及前馈网络用于最终的预测。值得注意的是，DETR 中编码器和解码器的具体结构与标准 Transformer 模型存在细微差异，其

架构详见图 4.4。




图 4.4 DETR 模型结构图

从上图可见 DETR 模型集成了空间位置编码，该编码专门为图像数据的二维矩阵特性量身定制。解码器采用目标查询作为输入序列，这一参数既参与多头自注意力机制，也用于位置编码的设定。与 Transformer 的解码器相比，DETR 的解码器未引入掩码机制。之所以能够实现并行输出，是因为图像数据中的像素之间并不存在固有的、先天的依赖关系。在多头注意力模型构建过程中，我们通过在键矩阵 K 中嵌入空间位置编码，同步对接目标查询及查询矩阵 Q。

前馈神经网络对解码器的输出进行加工，精确预测并确定了目标类别的归属及其边界框。在模型训练阶段，采用了匈牙利算法对预测边界框与真实目标边界框进行二分图匹配，从而实现预测框与真实框的一一对应关系。未能成功匹配的预测框被归类为背景，参与损失函数的计算步骤。

4.3 RT-DETR 目标检测算法

对 DETR 模型架构进行精简处理后，其部署实施更为简便，且可直接从图像数据中实现目标预测，无需依赖人工设计的预设锚框执行检测任务。这一特性省却了后续的非极大值抑制 NMS 处理环节，从而降低了计算开销，实现了真正意义上的端到端目标检测。然而，在小目标检测任务中，DETR 模型表现欠佳，计算成本较高，且网络收敛需要大量的训练迭代。为解决上述问题，Deformable DETR^[70]引入了可变形注意力机制（Deformable Attention），策略不仅加快了模型收敛的速度，显著降低了运算资源的占用比例。Deformable DETR 模型在检测

小目标方面，得益于多尺度特征的引入而得到显著提升。DINO 模型^[71]通过去噪学习策略，改善了二分图匹配的稳定性，使得 DETR 模型的收敛速度显著提高。尽管进行了优化，但 DETR 模型在实时性方面仍存在一定局限性。为了达成这一目标，Real-Time DETR (RT-DETR)^[72]模型成为研究热点。RT-DETR 在结构上与 DETR 类似，但在整体架构和训练策略上进行了优化，极大地简化了计算难度。即便在训练迭代次数减少的情况下，RT-DETR 依然能够维持高检测精度，开启了实时目标检测的新篇章。本文将全面分析 RT-DETR 的网络架构组成。

本章以 RT-DETR 系列中参数量最小的 RT-DETR-R18 模型为研究对象，进行精心的分析。在模型构建中，采用 ResNet-18^[73]作为骨干网络，用于提取图像的特征特征。图 4.5 对 RT-DETR 的网络结构进行了深入剖析。




图 4.5 RT-DETR 模型结构图

从上图可以看出，RT-DETR 主要由 Backbone、Encoder 和 Decoder 三个部分构成，下面将依次介绍各部分。

(1) Backbone 部分

RT-DETR 的主干网络采用 ResNet-18 架构。该架构主要由卷积-批归一化-ReLU (CBR) 模块、最大池化 (MaxPool) 层和残差模块 (ResBlock) 构成。ResNet-18 利用残差结构融合主干分支与捷径分支的特征信息，并引入批归一化 (BN) 层以加速网络训练过程。

图 4.5 中 P1 至 P5 分别代表从原始图像中提取的，通过 2、4、8、16 和 32

因子进行的下采样所得。CBR 模块由卷积层、批归一化层以及 ReLU 激活函数组成，此模块的主要目的是提取图像的特征部分。通过 MaxPool 层中的最大池化操作，实现了下采样，从而显著降低了网络的参数数量。ResNet-18 的残差模块 ResBlock 采用逐点卷积（PointWise Convolution，简称 PWConv）在捷径分支上降低参数量，并在另一捷径分支上与主干分支的输出进行逐元素相加。编码器后续处理将采用主干网络中的 P3、P4 和 P5 层特征图进行特征融合。

（2）Encoder 部分

RT-DETR 编码器整合了两种异构特征处理机制：注意力驱动的同尺度特征关联模块（AIFI）与卷积式多尺度特征集成模块（CCFM）。前者通过全局注意力建模实现单层级语义增强，后者利用可变形卷积完成跨层级特征融合，形成互补性特征演进路径。

AIFI 模块沿用了 DETR 中的编码器设计，但仅采用单层结构，专注于处理骨干网络输出的 P5 层特征。选择 P5 层的原因在于该模型在深入挖掘语义信息的基础上，实现了高倍率下采样，有效减小了特征图的尺寸，进而大幅减少了计算压力。在 AIFI 模块的预处理阶段，需将二维图像特征展开成一条一维序列，待处理结束后，再将该序列还原为二维图像特征。

CCFM 模块作为多尺度特征融合的关键环节，对 P3、P4 和 P5 层的骨干网络特征进行了系统聚合。该结构仿照路径聚合网络 PAN 设计，构建了上下文双向特征融合的机制。CCFM 由多个子模块构成，包括卷积块序列 CBS、上采样操作 Upsample、特征融合模块 Fusion 以及可变形卷积块 PBS。其中，Fusion 模块负责拼接不同尺度的特征，并将其分流处理：一条数据流经过逐点卷积的 PWConv 处理，另一数据流则先进行 PWConv，再通过三次 RepBlock 的堆叠，最终将两条路径的输出结果相加，生成最终输出。该 CBS 模块由逐点卷积、批归一化（BN）和 SiLU 激活函数构成，其核心功能在于对图像特征进行下采样，对特征融合技术的未来发展具有推动力。最终 CCFM 模块将三路融合特征进行整合，形成最终的输出成果。

查询选择策略，即从编码器输出中筛选出特定数量的特征，这些特征将作为解码器初始查询的初始特征集合。具体操作上编码器的输出先通过线性映射得到各类别的分数，接着根据分数高低对特征进行排序，并最终选取分数最高的前 K 个特征作为解码器的输入。

（3）Decoder 部分

本解码器沿用了 DETR 的架构，但对其中的多头自注意力机制模块进行了替换，本解码器集成了 Deformable DETR 所创新的变形注意力模型。。该机制的具体运算流程详见下图 4.6。




图 4.6 可变形注意力机制示意图

本文以头数 Head 为 2、采样点数为 4 的配置为研究对象，对可变形注意力机制进行系统探讨与分析。不同于传统 DETR 的全面信息处理，可变形注意力机制巧妙地运用了可变形卷积的思路，对特征图中的关键点进行精确定位与采集。通过采用这种策略性的采样技术，计算量得到了有效减少，网络收敛速度大幅增加。从上图可见输入特征矩阵的参考框，源自 Query Selection 模块的输出，该输出为采样定位步骤提供了基准点。编码器 Encoder 的输出结果形成输入特征矩阵，矩阵维度的调整必须借助线性映射技术。通过第一组线性映射，Query 特征导出了四个采样位置的偏移值，这些偏移值在各个 Head 中显示出多样化的采样偏移行为。第二组线性映射将 Query 特征的偏移量转化为权重信息，随后运用 Softmax 函数进行归一化处理，最终确立了采样点的权重分配方案。通过分析采样点的位移数据，从输入特征矩阵中提取了相关特征值，并依据相应的注意力权重进行加权合并，从而获得了采样结果 Head1 和 Head2。利用线性映射，该结果最终导出了可变形注意力机制的输出。

采用 DINO 模型中的去噪学习策略，RT-DETR 解码器优化了二分图匹配的稳定性，有效提升了网络的收敛效率。该策略首先通过对真实目标框的类别标签施加随机噪声，并对其边界框坐标引入随机偏移量，生成一定数量的基于真实标注生成的含噪声的样本。根据噪声水平，这些查询被划分为正样本（噪声较小）和负样本（噪声较大）。这些含噪声的样本与解码器的原始输入一同参与解码过程。但是实际上在去噪学习阶段，解码器输出的样本无需参与二分图匹配，因为这些样本已经具备真实目标框信息，可直接参与损失函数的计算过程。引入去噪样本，实际上是通过提供额外的监督信息，辅助了正负样本的匹配，这一技术大

幅缩短了模型的训练过程。

解码器输出数据在预测头的作用下，经过线性变换，最终计算出的类别概率分布及边界框的参数值。在模型训练环节，我们通过二分图匹配算法来精确匹配预测边界框与真实标注边界框，积极探寻它们之间的最匹配的配对。未成功匹配的预测边界框被归类为负样本，并参与后续损失函数的计算。

4.4 针对 PCB 组件检测任务的轻量化改进 RT-DETR 模型算法

4.4.1 EfficientPCB-DETR 模型

RT-DETR 模型在目标检测任务中展现出卓越的性能。然而由于其基于 Transformer 架构，该模型不可避免地存在参数量庞大、内存占用高等固有局限性。本研究旨在针对 RT-DETR 模型进行优化，提出 EfficientPCB-DETR 模型，我们核心目标聚焦于两个关键维度：降低模型参数量和提升目标检测精度，这种改进是有一定意义的。具体改进措施包括以下三个方面：选取高效的 EfficientFormerV2 主干网络替换原有主干、使用 HiLo 注意力优化 AIFI 中的多头自注意力以及使用轻量化设计的上采样模块。经过上述改进后的 EfficientPCB-DETR 模型结构示意图如图 4.7 所示。




图 4.7 EfficientPCB-DETR 模型结构示意图

4.4.2 主干网络改进

本章的研究采用 EfficientFormer^[74]的 V2 版本^[75]替代 RT-DETR 原有主干 ResNet-18 网络。EfficientFormerV2 在 V1 版本的基础上进行了诸多结构优化，显著提升了检测性能。下文将基于 EfficientFormerV2 的最小规模模型 S0 进行详细阐述与实验分析，其网络结构详见图 4.8。




图 4.8 EfficientFormerV2-S0 结构示意图

图 4.8 所示的注意力机制与 Transformer 模型中的注意力机制相似，但进行了如下改进：为提高模型的表达力，本研究在计算过程中引入了偏置参数，一并引入了偏置参数这一组成部分。运用 Talking Head 策略实现了不同注意力头间的信息互动，全连接层是该模块技术实现的核心技术核心部分。运用 Locality 模块我们采用卷积运算，将局部上下文信息汇合到值矩阵 V 。其中注意力模块 Attention Block 的构建是由包含残差连接的注意力机制单元和标准块 (Block) 组

合而成。为了克服高分辨率图像特征所引发的计算效率难题,本研究引入了具有步长功能的注意力机制,图 4.8 详细展示了 **Attention_1** 模块的运作机制。具体操作上我们首先对图像特征进行降采样,然后采用注意力机制进行深度学习处理,最后通过上采样技术将输出图像恢复至原始尺寸,从而降低了计算复杂度。**Attention Subsample** 模块这一创新设计,不再采用传统的卷积下采样技术,采用了注意力引导的下采样方法。其具体实现过程如下:该模块并行构建了两条下采样路径。第一条采用平均池化作为一种静态的局部下采样手段;在第二条分路中引入深度可分离卷积作为一种具备可学习参数的动态下采样手段。将上述两条路径所产生的下采样结果进行逐元素加和 (**Element-wise Summation**),随后将融合后的特征映射至输出矩阵 **Q**。最后一步是残差连接与信息整合,为了进一步整合局部与全局特征信息,将注意力下采样所得结果与通过卷积操作得到的下采样结果进行残差连接。

EfficientFormerV2 借鉴了 **Transformer** 模型对注意力机制实施了高效优化。通过采用逐点卷积 (**PWConv**) 和深度卷积 (**DWConv**),该网络在降低模型参数量的基础上,计算效率的进步非常显著。图 4.9 全面剖析了传统与深度卷积的特性差异。




图 4.9 传统卷积和深度卷积示意图

从图 4.9 中我们可以观察到,在传统卷积操作中,卷积核的通道数与输入特征图的通道数同步匹配;而在深度卷积操作中,卷积核的通道数固定为单一数值 1。采用深度卷积方法,可以显著减少模型参数,进而提高参数的效率水平。

EfficientFormerV2 模型的核心架构包含以下几个关键组件:嵌入层 (**Embedding**)、特征提取块 (**Block**)、下采样层 (**Subsample**)、注意力块 (**Attention Block**) 以及注意力下采样层 (**Attention Subsample**)。Embedding 层由卷积层 (**Conv**)、批归一化层 (**BN**) 和 **GELU** 激活函数构成。卷积层对图像数据执行

2 倍下采样，从而空间维度减小了。Block 模块在图像深层特征提取中占据核心地位，该模块的构建主要采用了点卷积（PWConv）、深度可分离卷积（DWConv）以及残差连接技术。该模块先利用逐点卷积降低特征维度以压缩信息，随后通过深度卷积捕获局部上下文信息，再应用逐点卷积恢复特征维度，最终将处理后的特征与初始输入进行逐元素相加，形成残差连接。

4.4.3 基于注意力机制的改进 AIFI

PCB 图像的高频部分揭示局部细节，低频成分主要揭示整体轮廓。然而 AIFI 模块中的多头自注意力机制并未区分不同频率的特征。为解决这一问题，本研究引入 HiLo（High-Low Frequency Attention）注意力机制^[76]改进 AIFI 模块。HiLo 是针对工业检测场景设计的混合注意力机制，核心思想是通过分离高频与低频特征处理来解决传统 Transformer 在工业图像分析中的两个关键问题：高频信息丢失和计算冗余。相比于传统全局注意力，在降采样过程中会保留更多的焊点、微小组件等高频细节同时减少计算量。HiLo 具体结构如图 4.10 所示。




图 4.10 HiLo 结构示意图

从上图可以观察到，HiLo 模型将注意力头划分为两个组别，对高频 G_h 与低频 G_l 注意力分别采取特定手段。对于输入特征图 $X \in \mathbb{R}^{H \times W \times C}$ ，其高频分支的图像特征被细分为 2×2 的子区块，每个子区块内部采用自注意力机制，聚焦于高频特征的关键提取，计算局部注意力具体公式如 4.5 所示：

$$A_h = \text{softmax}\left(\frac{Q_h K_h^T}{\sqrt{d_k}}\right) V_h \quad (4.5)$$

其中 $Q_h, K_h, V_h \in \mathbb{R}^{(H/2 \times W/2) \times 4 \times C}$ ，即高宽减半，通道数变为原来的 4 倍。这种方法不依赖全局注意力，大幅降低计算复杂度要求。多头自注意力机制在全

局层面上对低频信息的捕捉有显著作用,但在高分辨率特征图上的应用却会带来巨大的计算消耗。

对于低频分支,先采用平均池化层进行处理得到 $X'_h \in \mathbb{R}^{(H/2 \times W/2) \times C}$, 这一层相当于一个低通滤波器,能够从输入数据中提取低频成分,数据被嵌入到值 (V'_l) 矩阵及键 (K'_l) 矩阵的构成中,而查询 (Q'_l) 矩阵则直接由初始输入生成。随后计算全局注意力具体公式如下 4.6 所示:

$$A_l = \text{softmax} \left(\frac{Q_l K_l'^T}{\sqrt{d_k}} \right) V'_l \quad (4.6)$$

其中 $K'_h, V'_h \in \mathbb{R}^{(H/2 \times W/2) \times C}$, 进一步的压缩了通道数,由于 V'_l 矩阵和 K'_l 矩阵的数据规模减小,低频部分的计算压力与高频部分相比有所下降。

通过在通道维度上对高频与低频分量进行拼接融合,我们得到了最终的输出 Y , 具体公式如下 4.7 所示:

$$Y = \text{Concat}(A_h, A_l) W_o + X \quad (4.7)$$

其中 W_o 为可学习投影矩阵, $W_o \in \mathbb{R}^{2C \times C}$, X 为原始的输入特征图。

为了提高 AIFI 模块的效率,本研究采用了 HiLo 注意力机制,用新型多头自注意力模块替换了旧模块。改进后的 AIFI 结构如图 4.11 所示。其中前馈网络由两层线性映射层和一个 GELU 激活层组合而成。首先对数据进行线性升维处理,接着应用 GELU 激活函数,最后通过第二层线性映射实现降维,我们的目标是通过这一过程恢复数据的原始维度。HiLo 注意力机制采用 8 个头部单元,高频与低频部分的头部单元数量各为 4,实现了平均分割。




图 4.11 AIFI 融合 HiLo 结构示意图

4.4.4 轻量化上采样改进

在 RT-DETR 模型中,原有的上采样模块采用了最近邻插值法。该方法具有实现简便、计算效率高的优点,但是模型在采样连续性方面存在不足。为了解决这一技术难题,本研究采用了 DySample^[77]轻量化的动态上采样技术,替换了原上采样方法。现有的上采样方法如 CARAFE、FADE、SAPA 等,依赖于动态卷积来生成上采样的内容感知核,但这些方法需要额外的子网络生成动态卷积核,

计算量较大。DySample 的核心思想是将上采样过程重新定义为点采样（Point Sampling）。通过学习输入特征图中的采样点坐标，DySample 生成内容感知的采样点来对特征图进行重新采样，而不是使用动态卷积核。图 4.12 对本文所论述的 DySample 结构进行了详尽的阐释。




图 4.12 DySample 结构示意图

上图中输入图像的维度表示为 $H \times W \times C$ ，分别代表图像的高度、宽度和通道数。该图像经过一次线性映射，其通道数变换为 $2gs^2$ ，其中 2 表示采样点在二维空间中的坐标分量横坐标和纵坐标，分组数量用 g 表示，后续操作将在通道维度上依据 g 值进行分割，保证各分组处理互不干扰。后通过 Pixel Shuffle 操作，将图像像素从通道维度转移到空间维度（即高度和宽度），实现了图像上采样，大幅提高了图像的分辨率质量。将偏移量与初始网格数据逐个元素相加，从而得到准确的采样点坐标。在原始图像中选取采样点，并利用双线性插值技术进行上采样，提取了采样输出结果 Output。

4.5 实验结果及分析

4.5.1 数据集、实验环境及训练设置

数据集：本章实验所使用的数据集仍然是基于我们提出的 SPCB-Datasets

实验环境：本章实验的实现依托于开源深度学习框架 PyTorch。所有消融实验都是在 PC 端 Ubuntu20.04 系统下完成的，硬件配置 CPU 为 Intel i9-10900KF，GPU 为 NVIDIA RTX3090，显存容量为 24GB。软件配置采用 Python3.8 编程语言，使用 CUDA11.3 和 Cudnn8.2.2 对 GPU 加速。以保证实验的公平性与可重复性，所有的实验均在相同的实验环境下进行，具体实验环境如下表 4.1 所示。

表 4.1 实验环境

实验环境配置	
操作系统	Ubuntu20.04 64bit
语言	Python3.8
CUDA	11.3
Cudnn	8.2.2
GPU	NVIDIA RTX3090
CPU	Intel i9-10900KF

训练设置：为保障实验的公平性、可对比性，我们对网络模型训练中的参数进行统一设置，实验中对于网络训练的具体参数配置如下：训练轮次 300 个 epoch，初始学习率为 0.0001，采用余弦退火策略调整学习率，使模型快速收敛到局部最优值，批次大小为 16，学习率动量值为 0.9，使用 AdamW 优化器，其余参数使用默认值。

4.5.2 实验结果

本小节实验对比了我们改进后的模型 EfficientPCB-DETR 与原模型 RT-DETR 的参数量、精确率、召回率以及 mAP@0.5 指标。实验结果如下表 4.2 所示。

表 4.2 RT-DETR 模型对比实验结果表

模型	参数量 (M)	精确率 (%)	召回率 (%)	mAP@0.5(%)
RT-DETR	24.79	85.2	86.3	87.6
EfficientPCB-DETR	17.88	89.5	89.2	92.5

表 4.2 的数据分析结果表明，经过优化后的 EfficientPCB-DETR 模型在轻量化方面取得了显著进展，改进后的模型参数量减少了近 30%，模型轻量化的同时精确率、召回率、平均精度 mAP 也均有提升，精确率和召回率分别提升 4.3%和 2.9%，mAP@0.5 提升了 4.9%，在我们提出的数据集上可以达到 92.5%的平均精度，基本符合工业要求，可以较好地识别 PCB 组件，保障 PCB 硬件安全。

4.5.3 主干网络消融实验

为评估不同主干网络对 RT-DETR 模型性能的影响，本节选取了三种具有代

表性的网络进行消融实验，分别为：RT-DETR 模型原有的 ResNet-18、YOLOv5 网络优化中采用的 FasterNet-T0，以及本章所提出的 EfficientFormerV2-S0。实验结果详见表 4.3。其中性能指标 $mAP@0.5$ 表示交并比（IoU）阈值为 0.5 时的平均精度均值，模型参数量以百万（M）为单位。

表 4.3 三种主干网络消融实验结果表

主干网络	参数量 (M)	精确率 (%)	召回率 (%)	$mAP@0.5$ (%)
ResNet-18	24.79	85.2	86.3	87.6
FasterNet-T0	16.89	85.3	84.9	87.3
EfficientFormerV2-S0	18.18	86.5	86.2	88.5

从上表数据中可以看出，FasterNet-T0 作为核心网络，其参数量比 ResNet-18 减少了 7.9M，这无疑为 RT-DETR 模型的轻量化提供了坚实的支持基础。FasterNet 网络的成功很大程度上归功于其对 PConv 和点卷积技术的广泛应用，这一举措不仅降低了参数量，极大地加快了网络的训练与推理速度。尽管 FasterNet 的应用显著减小了模型规模，但仍保持了相对稳定的检测性能，精确率几乎保持不变，召回率、平均精度均值 mAP 略有下降，但总体影响不大。

采用 EfficientFormerV2-S0 网络同样实现了模型的轻量化。与 ResNet-18 相比，参数量减少了 6.61M；与 FasterNet-T0 相比，参数量仅增加 1.29M。值得注意的是，EfficientFormerV2-S0 在各项检测指标上均优于 FasterNet-T0，其中精确率提升 1.2%，召回率提升 1.3%， $mAP@0.5$ 提升 1.2%。得益于 EfficientFormer 网络结构中引入的 PWConv 与 DWConv，该网络成功实现了参数精简。该网络在特征提取和下采样环节，大量采用了改进的自注意力机制，这不仅增强了模型对全局和局部特征的捕捉能力，而且在实现模型轻量化的过程中，极大地增强了 PCB 组件检测的检测效率。

4.5.4 消融实验

继前一节对三种主干网络进行消融实验后，本节将聚焦于我们提出的三种优化策略进行消融实验研究。这三种优化策略分别为：采用 EfficientFormerV2-S0 网络替代原有主干网络、引入 HiLo 注意力机制以改进 AIFI 模块，以及运用 DySample 优化上采样过程。表 4.4 详细列出了消融实验的结果，其中涵盖了模型参数量（以百万为单位，M）、精确率、召回率以及 $mAP@0.5$ 为交并比阈值为 0.5 时的平均精度均值这四项关键性能评价指标。

表 4.4 消融实验结果表

EfficientFormer	AIFI_	DySample	参数量	精确率	召回率	mAP@0.5(
V2	HiLo		(M)	(%)	(%)	%)
			24.79	85.2	86.3	87.6
√			18.18	86.5	86.2	88.5
	√		24.65	86.6	87.5	89.2
		√	24.53	86.9	85.2	88.5
√	√		18.09	88.1	87.5	91.5
√	√	√	17.88	89.5	89.2	92.5

由上表我们可以看出在 RT-DETR 基准模型的基础上，替换主干网络为 EfficientFormerV2 后，参数量有明显的下降，减少了 6.61M，mAP@0.5 提升 0.9%；在此基础上继续使用 AIFI_HiLo 模块，相比于基准模型 mAP@0.5 提升了 3.9%；再加入 DySample 轻量化的上采样模块后，相比于基准模型，mAP@0.5 提升了 4.9%，改进后的 EfficientPCB-DETR 模型的 mAP@0.5 指标达到了 92.5%。

表 4.4 的数据揭示了，本章对 RT-DETR 模型所实施的轻量化策略，主要对核心主干网络进行优化重构。EfficientFormerV2 技术实施案例分析：现状与展望。采用该主干网络后，模型参数量减少了 6.61M，效果显著。与其他三种优化模块相比，其对模型参数量的影响微乎其微，变动有限。采用 EfficientFormerV2 作为主干特征提取网络，不仅实现了模型轻量化，还伴随着检测精度和平均精度均值 mAP@0.5 的提升。EfficientFormerV2 网络结构的性能提升，主要归功于其采用了点卷积和深度卷积，这两种技术有效缩小了网络参数的规模。自注意力机制的加入使得网络在全局特征提取上更为出色，从而显著提高了检测效果。

通过采用 AIFI_HiLo 技术，三种检测性能评价指标均得到了一定程度的增强，模型参数量有所下降。得益于 HiLo 注意力机制的应用，AIFI 模块的多头自注意力机制得以优化，从而更好地捕捉图像的不同频率特征。HiLo 注意力策略通过同步处理图像的高频和低频成分，极大地扩展了特征搜集的深度。同时通过采用局部窗口自注意力和平均池化策略，对模型参数规模进行了进一步的精简。DySample 作为一种轻量且高效的动态上采样方法，与原模型中的最近邻插值方法相比，模型参数减少了 0.26M 的参数量，同时实现了检测性能的全面提升，得益于基于待采样图像计算采样点的偏移信息，并依据此偏移信息在原始图像上执行采样过程。

4.5.5 对比实验及效果图展示

上一小节的消融实验已经验证了本文提出的 EfficientPCB-DETR 模型在 PCB 小目标检测任务中的有效性,为了评估其性能表现,本节研究选取了 6 种具有代表性的目标检测模型及其不同的骨干网络配置进行对比实验。这些模型包括 YOLOv5-small、YOLOv7-tiny、YOLOv8n、DETR、Deformable DETR 以及 RT-DETR,再加上我们第三章提出的 DFBA-YOLOv8 模型,所有模型均在相同的训练环境和数据集下进行训练,所有的 DETR 模型的主干都使用 ResNet50,其他参数均使用默认参数配置。对比实验的结果如下表 4.5 所示。

表 4.5 对比实验结果表

模型	参数量 (M)	mAP@0.5	mAP@0.5:0.95	FPS
YOLOv5-small	7.19	78.6%	56.1%	105
YOLOv7-tiny	6.02	52.7%	38.1%	131
YOLOv8n	3.20	83.4%	57.2%	113
DFBA-YOLOv8	3.43	88.6%	61.6%	103
DETR	23.89	79.4%	46.5%	49
Deformable DETR	22.56	84.6%	49.8%	53
RT-DETR	24.79	87.6%	53.9%	56
EfficientPCB-DETR	17.88	92.5%	57.8%	64

由上表的对比实验我们可以看出我们本章所提出的 EfficientPCB-DETR 模型在我们的数据集中, mAP@0.5 指标上表现得最好,达到了最高的 92.5%,比第三章提出的 DFBA-YOLOv8 模型的 88.6%高出 3.9%的 mAP@0.5,证明了我们提出的 EfficientPCB-DETR 模型在 PCB 组件小目标任务上是有效的。我们还可以看到, DFBA-YOLOv8 模型的参数量较小, FPS 也能达到与 YOLOv8n 几乎一致的 103,比 DETR 系列模型参数量有明显地减少, FPS 比 DETR 系列普遍更高。这也说明 DFBA-YOLOv8 模型更加适合部署在边缘化的设备中,适合用于对 FPS 有较高要求的场景中;而 EfficientPCB-DETR 模型更加适合在工业领域中运用,因为该模型的平均精度更高,同时 FPS 也能达到 64,符合工业需求。

图 4.13 所示为五种模型的检测效果对比图,其中 (a) 为图片的基准真值 (Ground-Truth); (b) 是我们改进后的 EfficientPCB-DETR 模型检测结果; (c) 为 DFBA-YOLOv8 模型,其中的红色箭头表示对组件文本这一类别产生了多余的预测框,同时我们也可以看到 EfficientPCB-DETR 模型的检测精度高于

DFBA-YOLOv8; (d) 为 YOLOv8n 的检测结果, 有三个多余的检测框, 并且漏检了一个文本类别; (e) 为 Deformable DETR 的检测结果, 有四个多余的组件文本类别的检测框, 错检了一个文本类别; (f) 为 RT-DETR 的检测结果, 缺少一个组件文本类别, 属于漏检。




图 4.13 不同模型检测结果对比图

4.6 本章小结

本研究对采用 Transformer 架构的 PCB 组件目标检测技术进行了系统性的剖析。第一节详细介绍了 Transformer 的工作原理及其基本构成, 为后续对 DETR 模型的研究奠定了坚实的理论基础。第二节深入探讨了目标检测领域内, 基于 Transformer 架构的先驱性成果 DETR, 详尽解析了 DETR 的目标检测步骤, 本文对 DETR 与锚框预设依赖的目标检测模型的利弊进行了全面剖析。第三节详细介绍了 RT-DETR 模型, 这是在 DETR 模型基础上进行改进的一种新型模型, 对模型架构进行了全面的剖析与阐释。

第四节从减少模型参数规模和增强检测准确度两方面着手, 对 RT-DETR 模型进行了改进, 并针对 PCB 组件检测任务提出了 EfficientPCB-DETR 模型。以下是本次模型升级的核心内容: 将 EfficientFormerV2-S0 网络替换为 ResNet-18

作为基础网络；通过 HiLo 注意力机制对 AIFI 的多头注意力机制进行改进，命名为 AIFI_HiLo 采用 DySample 技术对上采样模块进行优化，有效减少参数量并提升检测效果。

第五节实验部分，我们依据提出的数据集，开展了一系列消融实验，分析所提出的优化策略在 PCB 组件检测领域的实际效能，并与第三章提出的模型以及其他各种目标检测模型进行了对比实验。最后通过对比实验结果，分析了我们所提出的两个模型：DFBA-YOLOv8 模型与 EfficientPCB-DETR 模型的优缺点以及使用场所。

第 5 章 模型在 PCB 硬件保障中的通用性研究

5.1 引言

上述章节已经充分证明我们所提出的两个 PCB 组件检测模型在我们给出的数据集上的有效性,在 PCB 硬件保障领域还有一项重要的检测任务,那就是 PCB 缺陷检测。尽管印制电路板的制造技术已经相当成熟,但在其复杂的制造过程中,由于操作失误或技术故障等多种原因,PCB 表面存在未熔接焊点、毛刺、缺口、残留铜渣、短路和开路等缺陷^[78]。这些缺陷的存在对电子产品的性能和可靠性构成了潜在的隐患^[79]。在 PCB 焊接环节电子元器件的焊接质量缺陷不容忽视,此类缺陷不可避免地会对电子产品的性能和可靠性造成不利影响^[80]。在追求 PCB 品质与可靠性的过程中,对 PCB 及元器件焊接质量的表面缺陷进行检测显得尤为重要^[81]。面对 PCB 表面缺陷的多样性、形态复杂、尺寸微小以及特征相似性,质量检测工作遭遇挑战重重。。

PCB 缺陷检测的难点与组件检测任务有着相似性,总结起来都是目标类型较小以及尺寸多样性,容易受到环境因素的干扰导致检测精度下降。所以本章我们将使用 PCB 缺陷检测任务领域公开的数据集来验证我们提出的模型在 PCB 硬件保障中的通用性。

5.2 PCB 缺陷检测数据集

PCB 缺陷检测任务的发展较 PCB 组件检测时间早、研究广。PCB 缺陷检测任务研究使用源自北京大学智能机器人开放实验室公开的 PCB 缺陷数据集^[82],该数据集包含 693 张图像,涵盖 6 类缺陷:漏孔(missing_hole)、鼠咬(mouse_bite)、开路(open_circuit)、短路(short)、余铜(spurious_copper)和毛刺(spur)。此数据集可支持图像分类、目标检测等多种计算机视觉任务的研究与应用。对于数据集内的缺陷位置以及检测框的信息统计如图 5.1,可以看出数据集中的缺陷分布均匀,尺寸大小总体偏小。




图 5.1 数据集标签统计图

由于该数据集样本量较少，我们考虑使用数据增强策略，为了公平起见使用了与 3.4.1 小节相同的增强策略，包括了传统的几何变换和形态学操作，包括旋转、翻转、转置和随机亮度对比度在内的色彩空间转换。借助这些增强技术，我们将图像细分为 600×600 像素的子图像，最终构建了一个包含 10668 张图像的 PCB 缺陷检测数据集。采用数据增强技术对 PCB 缺陷数据集进行处理，有效扩大了数据规模，一并显著提升了算法模型的泛化能力和鲁棒性。采用 6:2:2 的比例数据集随机划分成训练、验证和测试三个集合。表 5.1 详细展示了数据增强后的 PCB 缺陷数据集中各缺陷类型的具体划分情况。

表 5.1 PCB 缺陷检测数据集划分统计表

缺陷种类	训练集	验证集	测试集	总数
漏孔	1091	379	362	1832
鼠咬	1103	398	351	1852
开路	1070	334	336	1740
短路	1038	328	366	1732
余铜	1051	352	357	1760
毛刺	1047	342	363	1752
总数	6400	2133	2135	10668

下图 5.2 展示了数据集内的六种缺陷类型图示，图中红色标注框是不同缺陷的标注，可以看到缺陷的尺寸十分的小，肉眼识别也有难度。




图 5.2 数据集中的六种缺陷类型图

5.3 基于深度学习的 PCB 缺陷检测研究现状

为了更好地验证我们所提出的模型在 PCB 缺陷检测上的应用价值，需要与前人研究的已有模型进行对比实验。学者 You 的研究^[83]展示了一种基于生成对抗网络（GAN）的 PCB 表面缺陷检测技术，该技术通过边缘增强超分辨率生成对抗网络（ESRGAN）对 PCB 图像进行处理，准确识别了六种不同类型的 PCB 表面缺陷。

何国忠等人^[84]在 YOLOv4 基线模型的基础上，通过引入注意力机制及增加空间金字塔池化模块数量，明显增强了 PCB 表面缺陷检测的检测精度。该算法的平均精度均值高达 91.40%，在性能上远超常规的卷积神经网络算法。划痕类型缺陷的检测精度目前为 56.46%，该结果揭示了检测技术有待进一步提高的空间。

针对小目标检测的挑战，Wang 等研究者^[85]提出了一种新方法，即用双向特征金字塔网络（BiFPN）替代 YOLOv5 的主干网络，对锚框设计进行了优化调整。

Hu 等^[86]在 Faster R-CNN 算法的基础上进行了改进，于主干网络部分引入了融合特征金字塔网络的 ResNet50 算法，以增强模型对小尺寸 PCB 缺陷的检测能力。同时，该研究采用了基于导向锚定的区域生成网络（GA-RPN）来精确预测锚框，并采用 ShufflenetV2 残差单元进行特征融合，与 Faster R-CNN 基线模型

相比，模型在精度上提升了 9%，速度提升达到了每图像 0.042 秒。

虞冰等^[87]提出了一种名为 YOLOX-WSC 的 PCB 缺陷检测算法，该算法采用弱化数据增强策略以加速模型收敛，同时引入 SimAM 和 CSPHB 等模块来增强特征提取和定位能力，实验结果表明，该算法在各个缺陷类别的平均精度上均有显著提升，mAP@0.5 达到了 96.65%。

文斌等^[88]提出了一种名为 LWN-Net 的轻量级缺陷检测网络，解决了特征提取阶段语义信息与位置信息不平衡的问题，以缓解由此导致的检测精度下降。实验结果表明，LWN-Net 模型规模为 28.19MB，检测精度可达 99.58%，帧率为 64.21FPS。

苏佳^[89]等的研究成果——YOLO-J 检测算法，小尺寸 PCB 板表面缺陷检测的应用方式。在 YOLOv4 算法的基础上，对核心网络、PANet 路径聚合网络以及颈部网络的激活函数进行了改进，实验结果显示，改进后的算法在检测性能上有了明显提升，但模型体积仍为 132MB，后续研究将致力于进一步降低模型体积。

5.4 对比实验研究

本章的对比实验是为了验证我们提出的两个网络模型是否在 PCB 缺陷任务上也具有实用性，使用的数据集是我们增强后的 PCB 缺陷数据集，硬件配置与前文中的配置一致，训练中的参数设置也统一使用前文中的配置，所有试验均保持一致，均训练 300 个 epoch，批次大小均为 16。

对比实验的结果如下表 5.2 所示，我们对比了主流的目标检测网络以及前人在 PCB 缺陷检测领域中的模型研究。

表 5.2 对比实验结果表

模型	参数量 (M)	mAP@0.5	mAP@0.5:0.95	FPS
Faster RCNN	41.14	53.9%	36.7%	29
YOLOv4-tiny	6.65	62.9%	45.4%	131
YOLOv5-small	7.19	66.4%	50.1%	115
YOLOv7-tiny	6.02	65.5%	49.1%	129
YOLOv8n	3.20	73.2%	52.1%	112
DETR	23.89	62.8%	43.5%	62
Deformable DETR	22.56	69.4%	48.8%	68
RT-DETR	24.79	78.5%	51.4%	72

续表 5.2 对比实验结果表

模型	参数量 (M)	mAP@0.5	mAP@0.5:0.95	FPS
Faster-PCB ^[86]	38.42	70.5%	51.9%	16
YOLOv4-PCB ^[84]	7.16	68.2%	48.1%	120
YOLOv5-PCB ^[85]	7.91	81.3%	57.6%	113
YOLOX-WSC ^[87]	5.16	72.1%	50.8%	85
LWN-Net ^[88]	29.5	80.5%	55.2%	35
YOLO-J ^[89]	6.89	82.2%	59.4%	97
DFBA-YOLOv8	3.43	88.3%	63.6%	117
EfficientPCB-DETR	17.88	85.6%	61.6%	76

上表 5.2 我们分别对比了常见的目标检测模型 YOLO 以及 DETR 系列，后面对前人研究中的模型进行对比实验，最后是本文提出的两个 PCB 组件检测模型。

我们可以从表格实验结果中可以看到：基准模型在 PCB 缺陷检测任务上的表现一般，其中 YOLOv8n 和 RT-DETR 模型的 mAP@0.5 分别可以达到 73.2%和 78.5%。而针对 PCB 缺陷检测任务设计的专用模型优势显著，改进模型的 mAP@0.5 普遍超过通用模型，其中检测精度最高的是 YOLO-J 模型，mAP@0.5 达到 82.2%，同时 mAP@0.5:0.95 达到 59.4%，表明领域自适应优化如小目标检测增强、特征融合等对精度提升至关重要。YOLOv8n 和 RT-DETR 作为通用模型已经有着不错的表现，我们提出的 DFBA-YOLOv8 通过引入 DCNv4 模块更好地提取特征、提出一种关注感受野的卷积模块，替换了原网络颈部下采样操作的 C2f 结构，提升模型定位的精度，改善网络的整体性能和效率，以及 BPFPN 的设计让模型更好地适合小目标的任务，将 mAP@0.5 指标提升至 88.3%，同时 mAP@0.5:0.95 达到 63.6%；而 EfficientPCB-DETR 通过替换主干网络、轻量化设计进一步将 mAP@0.5 指标提升至 85.6%，验证了 Transformer 架构在工业检测中的可行性。

在模型的轻量化方面，YOLO 系列模型有着很大的优势，我们提出的 DFBA-YOLOv8 以仅 3.43M 参数量实现 88.3% mAP@0.5，仅仅比 YOLOv8n 模型的参数量多了 0.23M，而 EfficientPCB-DETR 的参数量为 17.88M，仍是 YOLO 系列的 2-5 倍，需进一步轻量化。在模型检测速度方面，轻量化的 YOLO 系列变体如 YOLOv4-tiny、YOLOv8n，及改进后的模型 DFBA-YOLOv8 在 FPS 指标上均超过 100，满足工业实时检测需求。EfficientPCB-DETR 通过结构优化将 FPS 提升至 76，较原始 DETR 的 62FPS 基础上提升了 22.6%，但与 YOLO 系列仍有

差距。实验说明在 PCB 缺陷检测任务上，我们提出的 DFBA-YOLOv8 模型在检测精度、速度、模型参数量上均有着一定的优势，具有一定的工业应用价值。

对于 EfficientPCB-DETR 与 DFBA-YOLOv8 跨任务表现的差异，分析可能是由于以下几个方面：（1）PCB 组件检测任务中电阻、电容等具有明确形状、固定尺寸，且分布相对规律，全局语义关联性强；而 PCB 缺陷检测任务中缺陷（毛刺、短路等）形态不规则、尺寸微小（多数 $<32\times32$ 像素），且与背景对比度低。

（2）EfficientPCB-DETR 模型中的 HiLo 注意力在微小缺陷如鼠咬时，同时包含高频（边缘突变）与低频（区域缺失）特征，双分支处理可能导致特征冲突，使得在缺陷检测中的效果下降；DFBA-YOLOv8 中的 DCNv4 的引入让模型动态适应缺陷边缘的不规则形状，增强局部特征提取。同时多尺度特征融合 BFPN 模块，可以更好地通过高分辨率特征图保留微小缺陷细节。我们得出结论 EfficientPCB-DETR 与 DFBA-YOLOv8 的性能差异本质源于任务特性与模型归纳偏置的匹配度，在规则目标、丰富上下文的组件检测任务中，EfficientPCB-DETR 的全局建模占优，而在不规则小目标、局部特征依赖的缺陷检测任务中，DFBA-YOLOv8 的性能表现更好。

下面选取性能较好的基准模型 YOLOv8n 和针对 PCB 缺陷检测任务设计的模型 YOLO-J，还有本文提出的两个模型的检测效果图进行展示，图 5.3 所示为各种缺陷的 Ground-Truth 图。图 5.4 为 YOLOv8n 模型的检测图，存在毛刺类别的一处漏检。图 5.4 为 YOLO-J 模型的检测图，在开路、短路、毛刺、多铜类别均有一处漏检，精度比 YOLOv8n 较好。图 5.6 为 DFBA-YOLOv8 模型的检测图，没有出现漏检的现象，平均检测精度比其他模型高。图 5.7 为 EfficientPCB-DETR 模型的检测图，在多铜类别上出现了一处漏检。




图 5.3 原始未检缺陷图




图 5.4 YOLOv8n 模型检测图




图 5.5 YOLO-J 模型检测图




图 5.6 DFBA-YOLOv8 模型检测图




图 5.7 EfficientPCB-DETR 模型检测图

5.5 本章小结

本章通过 PCB 硬件保障的另一个领域——PCB 缺陷检测来评估我们提出的模型在工业场景中的应用价值。我们针对 PCB 缺陷检测任务样本量少（原始数据仅 693 张）、缺陷尺寸小的挑战，基于北京大学智能机器人开放实验室公开数据集（涵盖漏孔、鼠咬、开路等 6 类缺陷），提出多维度数据增强方案，同时也将图像分割为 600×600 像素的子图像，最终形成了包含 10668 张图像的 PCB 缺陷检测数据集。在统一实验环境下，对经典模型、专用改进模型及我们提出的两种模型进行对比实验，给出了几种有代表性的模型的检测效果图，实验表明所提出的 DFBA-YOLOv8 与 EfficientPCB-DETR 模型在精度、效率和鲁棒性上均显著优于现有方法，验证了其在工业 PCB 缺陷检测中的实际应用潜力，为后续工程化落地奠定了算法基础。

第6章 总结与展望

6.1 工作总结

本文针对当前 PCB 组件检测中存在的挑战：PCB 组件尺寸小、存在低类间方差、有限的数据集等问题，提出了两种针对性的检测算法，并收集制作了 SPCB 数据集，经实验验证了模型的有效性。第一种算法主要是为了解决 PCB 组件目标尺寸较小、占总体面积占比小，目标与 PCB 背景对比度低、容易受到光照影响，组件目标分布无规律等问题，导致小组件的误检和漏检现象频繁出现。第二种算法则是关注与进一步地提升检测精度，提升工业中的硬件保障能力。最后为了验证我们所提出模型的硬件保障通用性，使用了数据增强后的 PCB 缺陷数据集，经过一系列的对比实验证明了我们提出模型的有效性和通用性。

第一种算法是基于 YOLOv8n 模型进行改进的 DFBA-YOLOv8，有以下四个方面改进：（1）为解决小尺度特征提取的挑战，本研究在主干网络与颈部间引入可变形卷积模块 DCNv4 旨在增强网络提取关键特征的能力，进而提高目标检测的准确性；（2）此外，针对复杂的目标和场景，提出一种关注感受野的卷积模块 RFACnv，替换了原网络颈部下采样操作的 C2f 结构。该模块能够提升模型定位的精度，改善网络的整体性能和效率；（3）针对小目标场景下的检测精度问题，本研究在颈部结构中引入了一种基于 BiFPN 改进的 BPFN 的多尺度特征融合结构，并且针对 PCB 微小组件检测任务舍弃了较大目标检测头，增加了较小目标检测头；（4）提出检测头 AMD_Detect Head 替换原检测头，通过将注意力函数分解为三个独立的序列注意力机制，分别关注不同的维度，以此显著降低计算复杂性并提升处理效率。最后通过消融实验和对比实验验证了本算法在 SPCB 数据集下的检测效果有不错的表现，兼具精度和检测速度。

第二种算法就是基于 RT-DETR 模型提出的，针对 DFBA-YOLOv8 在精度上还有进一步提升的空间，在工业中尽可能地保证 PCB 的硬件安全，针对需要高检测精度的场景，我们提出了 EfficientPCB-DETR 模型提出了三种策略用以去提升模型的性能，这三种策略为：选取高效的 EfficientFormerV2 主干网络替换原有主干、使用 HiLo 注意力优化 AIFI 中的多头自注意力以及使用轻量化设计的 DySample 上采样模块。最后通过消融实验和对比实验验证了本算法的有效性，证明了本算法在精度上有所提升， $mAP@0.5$ 指标达到了 92.5%，比 DFBA-YOLOv8 模型的 88.6%高出 3.9%的 $mAP@0.5$ ，更加适合在工业领域中运用，证明了我们提出的 EfficientPCB-DETR 模型在 PCB 组件小目标任务上是有

效的。

6.2 工作展望

本文提出的基于 YOLOv8n 模型进行改进的 DFBA-YOLOv8 和基于 RT-DETR 改进的 EfficientPCB-DETR 模型在 PCB 组件检测任务上取得了较好的效果，第五章的工作也证明了这两个模型在 PCB 缺陷检测任务上也具有一定的优势，具有工程应用价值。但是同样也存在着一些问题，本人发现本研究未来可以从以下几个方面继续改进：

（1）PCB 组件类型多种多样，本研究仅关注九种常见的 PCB 表面组件，未来的研究可考虑纳入更广泛的 PCB 组件类型，并增加每种组件类型的样本多样性，以增强模型对不同组件的适应性和学习能力。

（2）目前我们的研究只能识别特有组件的类别，不能够识别出例如二极管的正反、电阻电容的数值等问题，如果能够实现 PCB 的逆向工程，还需要识别出 PCB 上各组件间的连线。本研究具有一定的局限性，想要实现上述问题，需要有特殊的标签标注方式，目前还没有这方面的研究以及数据集。

（3）本文提出的两种检测模型，DFBA-YOLOv8 模型的优势是检测速度，在精度上 EfficientPCB-DETR 模型会更高，但是伴随的是模型参数量的提高、检测速度降低。未来工作可以考虑新的基准模型，在精度和速度上进一步提升，介于工程应用场景，PCB 组件检测任务不需要部署在边缘化设备，模型的参数量、计算量影响不大。

参考文献

- [1] Jahani N, Sepehri A, Vandchali H R, et al. Application of Industry 4.0 in the Procurement Processes of Supply Chains: A Systematic Literature Review[J]. Sustainability, 2021, 13.
- [2] Shi Y, Xin Z, Loh P C, et al. A Review of Traditional Helical to Recent Miniaturized Printed-Circuit-Board Rogowski Coils for Power Electronic Applications[J]. IEEE Transactions on Power Electronics, 2020, PP(99):1-1.
- [3] Leta F R, Feliciano F F. Computational system to detect defects in mounted and bare PCB based on connectivity and image correlation[C]. 2008 15th International Conference on Systems, Signals and Image Processing. IEEE, 2008: 331-334.
- [4] Iwahori Y, Futamura K, Adachi Y. Discrimination of true defect and indefinite defect with visual inspection using SVM[C]. Knowledge-Based and Intelligent Information and Engineering Systems: 15th International Conference, KES 2011, Kaiserslautern, Germany, September 12-14, 2011, Proceedings, Part IV 15. Springer Berlin Heidelberg, 2011: 117-125.
- [5] Iwahori Y, Kumar D, Nakagawa T, et al. Improved defect classification of printed circuit board using SVM[C]. Intelligent Decision Technologies: Proceedings of the 4th International Conference on Intelligent Decision Technologies (IDT' 2012)-Volume 2. Springer Berlin Heidelberg, 2012: 355-363.
- [6] Mehta D, Lu H, Paradis O P, et al. The big hack explained: Detection and prevention of PCB supply chain implants[J]. ACM Journal on Emerging Technologies in Computing Systems (JETC), 2020, 16(4): 1-25.
- [7] Russell J M. Counterfeit electronic parts controls in the Department of Defense supply chain[D]. Monterey, California: Naval Postgraduate School, 2015.
- [8] Li J, Gu J, Huang Z, et al. Application research of improved YOLO V3 algorithm in PCB electronic component detection[J]. Applied Sciences, 2019, 9(18): 3750.
- [9] Cao S, Parvizioman I, Yang H, et al. Prediction of component shifts in pick and place process of surface mount technology using support vector regression[J]. Procedia Manufacturing, 2019, 39: 210-217.
- [10] Mallaiyan Sathiaselan M A, Paradis O P, Taheri S, et al. Why is deep learning challenging for printed circuit board (pcb) component recognition and how can we address it?[J]. Cryptography, 2021, 5(1): 9.
- [11] Quadir S E, Chen J, Forte D, et al. A survey on chip to system reverse engineering[J]. ACM journal on emerging technologies in computing systems (JETC), 2016, 13(1): 1-34.
- [12] Hassanin A A I M, Abd El-Samie F E, El Banby G M. A real-time approach for automatic defect detection from PCBs based on SURF features and morphological operations[J]. Multimedia Tools and Applications, 2019, 78(24): 34437-34457.
- [13] Polat S, Tremeau A, Boochs F. Combined use of 3D and HSI for the classification of printed circuit board components[J]. Applied Sciences, 2021, 11(18): 8424.
- [14] Kim J O, Lee Y A, Park T H. Automatic extraction of component inspection regions from printed circuit board[C]. 2012 IEEE/SICE International Symposium on System Integration (SII). IEEE, 2012: 871-876.
- [15] Xie F, Uitdenbogerd A, Song A. Detecting PCB component placement defects by genetic

- programming[C].2013 IEEE Congress on Evolutionary Computation. IEEE, 2013: 1138-1145.
- [16] Yuk E H, Park S H, Park C S, et al. Feature-learning-based printed circuit board inspection via speeded-up robust features and random RFast[J]. Applied Sciences, 2018, 8(6): 932.
- [17] Lu Z, He Q, Xiang X, et al. Defect detection of PCB based on Bayes feature fusion[J]. The Journal of Engineering, 2018, 2018(16): 1741-1745.
- [18] Qiang G, Shanshan Z, Yang Z, et al. Detection method of PCB component based on automatic optical stitching algorithm[J]. Circuit World, 2015, 41(4): 133-136.
- [19] Lin S C, Chou C H, Su C H. A development of visual inspection system for surface mounted devices on printed circuit board[C].IECON 2007-33rd Annual Conference of the IEEE Industrial Electronics Society. IEEE, 2007: 2440-2445.
- [20] Crispin A J, Rankov V. Automated inspection of PCB components using a genetic algorithm template-matching approach[J]. The International Journal of Advanced Manufacturing Technology, 2007, 35: 293-300.
- [21] Mashohor S, Evans J R, Erdogan A T. Automatic hybrid genetic algorithm based printed circuit board inspection[C].First NASA/ESA Conference on Adaptive Hardware and Systems (AHS'06). IEEE, 2006: 390-400.
- [22] Li D, Li C, Chen C, et al. Semantic segmentation of a printed circuit board for component recognition based on depth images[J]. Sensors, 2020, 20(18): 5318.
- [23] Yin H M. A template-matching-based fast algorithm for PCB components detection[J]. Advanced Materials Research, 2013, 690: 3205-3208.
- [24] Wang D Z, Wu C H, Ip A, et al. Fast multi-template matching using a particle swarm optimization algorithm for PCB inspection[C].Applications of Evolutionary Computing: EvoWorkshops 2008: EvoCOMNET, EvoFIN, EvoHOT, EvoIASP, EvoMUSART, EvoNUM, EvoSTOC, and EvoTransLog, Naples, Italy, March 26-28, 2008. Proceedings. Springer Berlin Heidelberg, 2008: 365-370.
- [25] Dong N, Wu C H, Ip W H, et al. Chaotic species based particle swarm optimization algorithms and its application in PCB components detection[J]. Expert Systems with Applications, 2012, 39(16): 12501-12511.
- [26] Mamidi J S S V, Sameer S, Bayana J. A light weight version of PCB defect detection system using YOLO V4 tiny[C].2022 International Mobile and Embedded Technology Conference (MECON). IEEE, 2022: 441-445.
- [27] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [28] Lan Z, Hong Y, Li Y. An improved YOLOv3 method for PCB surface defect detection[C].2021 IEEE International Conference on Power Electronics, Computer Applications (ICPECA). IEEE, 2021: 1009-1015.
- [29] Li C J, Qu Z, Wang S Y, et al. A method of defect detection for focal hard samples PCB based on extended FPN model[J]. IEEE Transactions on Components, Packaging and Manufacturing Technology, 2021, 12(2): 217-227.
- [30] Evangelidis A, Dimitriou N, Leontaris L, et al. A deep regression framework toward laboratory accuracy in the shop floor of microelectronics[J]. IEEE Transactions on Industrial Informatics, 2022, 19(3): 2652-2661.
- [31] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C].Proceedings of the IEEE international

- conference on computer vision. 2017: 2961-2969.
- [32] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [33] Li J, Gu J, Huang Z, et al. Application research of improved YOLO V3 algorithm in PCB electronic component detection[J]. Applied Sciences, 2019, 9(18): 3750.
- [34] Shen J, Liu N, Sun H. Defect detection of printed circuit board based on lightweight deep convolution network[J]. IET Image Processing, 2020, 14(15): 3932-3940.
- [35] Zhang K. Using deep learning to automatic inspection system of printed circuit board in manufacturing industry under the internet of things[J]. Computer Science and Information Systems, 2023, 20(2): 723-741.
- [36] Chen I C, Hwang R C, Huang H C. PCB defect detection based on deep learning algorithm[J]. Processes, 2023, 11(3): 775.
- [37] Liu X, Hu J, Wang H, et al. Gaussian-IoU loss: Better learning for bounding box regression on PCB component detection[J]. Expert Systems with Applications, 2022, 190: 116178.
- [38] Mantravadi A, Makwana D, Mittal S, et al. Dilated involutonal pyramid network (DInPNet): A novel model for printed circuit board (PCB) components classification[C].2023 24th International Symposium on Quality Electronic Design(ISQED). IEEE, 2023: 1-7.
- [39] Benjumea A, Teeti I, Cuzzolin F, et al. YOLO-Z: Improving small object detection in YOLOv5 for autonomous vehicles[J]. arXiv preprint arXiv:2112.11798, 2021.
- [40] Ling Q, Isa N A M, Asaari M S M. Precise detection for dense PCB components based on modified YOLOv8[J]. IEEE Access, 2023, 11: 116545-116560.
- [41] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C].Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [42] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [43] Girshick R. Fast r-cnn[C].Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [44] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [45] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C].Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [46] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C].Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [47] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C].Computer Vision – ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 – 14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [48] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C].Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
- [49] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767,

- 2018.
- [50] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
 - [51] <https://github.com/ultralytics/yolov5>
 - [52] Ge Z, Liu S, Wang F, et al. YOLOx: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.
 - [53] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.
 - [54] Reis D, Kupec J, Hong J, et al. Real-time flying object detection with YOLOv8[J]. arXiv preprint arXiv:2305.09972, 2023.
 - [55] Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984-108011.
 - [56] Zhang H, Wang Y, Dayoub F, et al. Varifocalnet: An iou-aware dense object detector[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 8514-8523.
 - [57] Li X, Wang W, Wu L, et al. Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection[J]. Advances in neural information processing systems, 2020, 33: 21002-21012.
 - [58] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]. Proceedings of the IEEE international conference on computer vision. 2017: 764-773.
 - [59] Zhu X, Hu H, Lin S, et al. Deformable convnets v2: More deformable, better results[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9308-9316.
 - [60] Wang W, Dai J, Chen Z, et al. InternImage: Exploring large-scale vision foundation models with deformable convolutions[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 14408-14419.
 - [61] Xiong Y, Li Z, Chen Y, et al. Efficient deformable convnets: Rethinking dynamic and sparse operator for vision applications[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 5652-5661.
 - [62] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
 - [63] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13713-13722.
 - [64] Zhang X, Liu C, Yang D, et al. RFAConv: Innovating spatial attention and standard convolutional operation[J]. arXiv preprint arXiv:2304.03198, 2023.
 - [65] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.
 - [66] Kuo C W, Ashmore J D, Huggins D, et al. Data-efficient graph embedding learning for PCB component detection[C]. 2019 IEEE winter conference on applications of computer vision (WACV). IEEE, 2019: 551-560.
 - [67] Lu H, Mehta D, Paradis O, et al. Fics-pcb: A multi-modal image dataset for automated printed circuit board visual inspection[J]. Cryptology ePrint Archive, 2020.

- [68] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [69] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C].European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [70] Zhu X, Su W, Lu L, et al. Deformable detr: Deformable transformers for end-to-end object detection[J]. arXiv preprint arXiv:2010.04159, 2020.
- [71] Zhang H, Li F, Liu S, et al. Dino: Detr with improved denoising anchor boxes for end-to-end object detection[J]. arXiv preprint arXiv:2203.03605, 2022.
- [72] Zhao Y, Lv W, Xu S, et al. Detsr beat yolos on real-time object detection[C].Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 16965-16974.
- [73] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C].Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [74] Li Y, Yuan G, Wen Y, et al. Efficientformer: Vision transformers at mobilenet speed[J]. Advances in Neural Information Processing Systems, 2022, 35: 12934-12949.
- [75] Li Y, Hu J, Wen Y, et al. Rethinking vision transformers for mobilenet size and speed[C].Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 16889-16900.
- [76] Pan Z, Cai J, Zhuang B. Fast vision transformers with hilo attention[J]. Advances in Neural Information Processing Systems, 2022, 35: 14541-14554.
- [77] Liu W, Lu H, Fu H, et al. Learning to upsample by learning to sample[C].Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6027-6037.
- [78] 王恒涛,张上,张朝阳,刘展威.基于 YOLOv5 的轻量化 PCB 缺陷检测[J].无线电工程, 2022, 52(11):2094-2100.
- [79] 伍习东.基于深度学习的 PCB 图像缺陷检测研究[D].安徽理工大学,2021.
- [80] 伍济钢,成远,邵俊,等.基于改进 YOLOv4 算法的 PCB 缺陷检测研究[J].仪器仪表学报, 2021(10):171-178.
- [81] Hou Q, Sun J, Huang P. A novel algorithm for tool wear online inspection based on machine vision[J]. The International Journal of Advanced Manufacturing Technology, 2019, 101: 2415-2423.
- [82] <http://robotics.pkusz.edu.cn/resources/dataset/>
- [83] You S. PCB defect detection based on generative adversarial network[C].2022 2nd international conference on consumer electronics and computer engineering (ICCECE). IEEE, 2022: 557-560.
- [84] 何国忠,梁宇.基于卷积神经网络的 PCB 缺陷检测[J].图学学报, 2022(043-001).DOI:10.11996/JG.j.2095-302X.2022010021.
- [85] Wang X, Zhang X, Zhou N. Improved YOLOv5 with BiFPN on PCB defect detection[C].2021 2nd International Conference on Artificial Intelligence and Computer Engineering (ICAICE). IEEE, 2021: 196-199.
- [86] Hu B, Wang J. Detection of PCB surface defects with improved faster-RCNN and feature pyramid network[J]. Ieee Access, 2020, 8: 108335-108345.
- [87] 庾冰,黄丽雯,唐鑫,等.基于 YOLOX-WSC 的 PCB 缺陷检测算法研究[J].计算机工程与应用, 2023, 59(10):236-243.DOI:10.3778/j.issn.1002-8331.2211-0143.
- [88] 文斌,胡晖,杨超.基于 LWN-Net 的 PCB 缺陷检测算法[J].计算机集成制造系统[2025-03-22].
- [89] 苏佳,贾欣雨,侯卫民.基于 YOLO-J 的 PCB 缺陷检测算法[J].计算机集成制造系统, 2024(11).